




# Analyse et visualisation de données

De la donnée brute au tableau de bord

IAOUSSE M'barek

2026



Ce **manuel** a été élaboré pour servir de support de cours principal pour l'élément *Analyse et visualisation de données* dispensé dans le cadre de la Licence Professionnelle DBT-DAIA (*Développement d'Applications et Intelligence Artificielle*) en Temps Aménagé à l'École Supérieure de Technologie de Casablanca (ESTC).

**L'auteur** : M'barek IAOUSSE, Enseignant-Chercheur à l'EST Casablanca, Université Hassan II de Casablanca.



Sauf indications contraires, le contenu de ce manuel électronique est disponible en vertu des termes de la [Licence Creative Commons Attribution 4.0 International](https://creativecommons.org/licenses/by/4.0/).

**Autorisations accordées :**

**Partager** – copier, distribuer et communiquer le matériel par tous moyens et sous tous formats.

**Adapter** – remixer, transformer et créer à partir du matériel pour toute utilisation, y compris commerciale.

**Sous réserve de citer l'auteur.**

© M'barek IAOUSSE (2026)

Pour citer ce manuel : M'barek IAOUSSE. (2026). **Analyse et visualisation de données**. École Supérieure de Technologie de Casablanca. Sous licence CC BY 4.0.

# Préface

Le présent manuel est le support de cours officiel de l'élément **Analyse et Visualisation des Données**, dispensé dans le cadre d'une formation en Développement d'Applications et Intelligence Artificielle.

La communauté étudiante visée par ce module provient de parcours techniques variés (DUT, BTS, DTS ou diplômes équivalents), ayant déjà acquis un bagage de base en programmation Python. La familiarité préalable avec la Data Science, l'analyse de données ou le Machine Learning n'est pas un prérequis : ce manuel se concentre volontairement sur ce qui précède et accompagne la modélisation — comprendre, préparer, explorer et représenter une donnée — sans aborder les algorithmes d'apprentissage automatique, qui font l'objet d'un module distinct.

Ce manuel vise à outiller les étudiants d'une **démarche méthodique et reproductible** face à un jeu de données : savoir le questionner avant de le modéliser, savoir le nettoyer avant de l'analyser, et savoir le représenter avant de le communiquer. Il introduit progressivement les statistiques descriptives nécessaires, l'écosystème Python (**pandas**, **numpy**, **matplotlib**, **seaborn**), les principes d'un entrepôt de données, puis la construction d'une solution de Business Intelligence avec Power BI et Taipy. Un cas pratique final relie ces notions dans un même projet.

La progression est volontairement graduelle : les chapitres 00 à 02 présentent l'analyse, la préparation et l'exploration ; le chapitre 03 organise les données pour l'analytique ; le chapitre 04 transforme ces données en solution BI ; le chapitre 05 réunit l'ensemble dans une étude de cas guidée.

## Prérequis

Le contenu de ce manuel est organisé pour des personnes ayant déjà une base et une expérience avec :

- la programmation en langage Python (variables, boucles, fonctions, structures de données de base) ;
- la manipulation élémentaire de fichiers et de tableaux.

Aucune connaissance préalable en analyse de données, en statistique ou en data visualization n'est nécessaire : les indicateurs utiles sont introduits et illustrés progressivement.

## Livres et ressources complémentaires

Ce manuel s'inspire des ouvrages de référence en analyse de données et en visualisation, notamment *Python for Data Analysis* (McKinney 2022), consacré à la manipulation de données avec **pandas**, ainsi que *Storytelling with Data* (Knaflitz 2015), référence sur la communication visuelle de résultats analytiques.

L'ensemble des exemples et exercices pratiques est développé en utilisant **Python** comme langage principal, avec **pandas** et **numpy** pour la manipulation des données, et **matplotlib/seaborn** pour la visualisation statique.

### Note

Les bibliothèques scientifiques Python évoluant rapidement, veuillez à utiliser un environnement virtuel basé sur Python 3.10 ou supérieur pour garantir la compatibilité des extraits de code présentés dans ce manuel.

# Table des matières

|                                                                                                  |           |
|--------------------------------------------------------------------------------------------------|-----------|
| <b>Préface</b>                                                                                   | <b>i</b>  |
| <b>Introduction à l'analyse de données</b>                                                       | <b>1</b>  |
| 1. Qu'est-ce que l'analyse de données ?                                                          | 1         |
| 1.1. Définition                                                                                  | 1         |
| 1.2. Data Analysis, Data Science, Business Intelligence, Machine Learning : quelles frontières ? | 1         |
| 2. Les quatre types d'analyse de données                                                         | 2         |
| 3. Les premiers indicateurs à connaître                                                          | 3         |
| 3.1. Compter et comparer                                                                         | 3         |
| 3.2. Résumer une variable numérique                                                              | 4         |
| 4. Le cycle de vie d'un projet d'analyse de données                                              | 6         |
| 5. Écosystème d'outils Python pour l'analyse de données                                          | 6         |
| 5.1. Bibliothèques cœur                                                                          | 6         |
| 5.2. Environnements de travail                                                                   | 6         |
| 5.3. Gestion de projet avec uv                                                                   | 7         |
| 5.4. Tendances récentes de l'écosystème                                                          | 7         |
| 6. Les métiers de la donnée                                                                      | 7         |
| Exercices                                                                                        | 8         |
| <b>Préparation des données</b>                                                                   | <b>11</b> |
| 1. Collecte de données                                                                           | 11        |
| 1.1. Les bases de données                                                                        | 11        |
| 1.2. Les fichiers plats et formats de données                                                    | 12        |
| 1.3. Les API                                                                                     | 12        |
| 1.4. Le <i>web scraping</i>                                                                      | 13        |
| 1.5. Open data et capteurs / IoT                                                                 | 13        |
| 2. Nettoyage des données                                                                         | 13        |
| 2.1. Les valeurs manquantes                                                                      | 13        |
| 2.2. Les valeurs aberrantes ( <i>outliers</i> )                                                  | 14        |
| 2.3. Doublons et incohérences                                                                    | 15        |
| 2.4. Vers une démarche de qualité des données                                                    | 15        |
| 3. Transformation des données                                                                    | 15        |
| 3.1. Encodage des variables catégorielles                                                        | 15        |
| 3.2. Normalisation et standardisation                                                            | 16        |
| 3.3. Discrétisation ( <i>binning</i> )                                                           | 16        |
| 3.4. Quelques transformations usuelles supplémentaires                                           | 16        |
| Exercices                                                                                        | 17        |
| <b>Exploration des données</b>                                                                   | <b>20</b> |
| 1. Statistiques descriptives                                                                     | 20        |
| 1.1. Tendances centrale                                                                          | 20        |
| 1.2. Dispersion                                                                                  | 21        |
| 1.3. Forme de la distribution                                                                    | 21        |
| 2. Analyse univariée, bivariée et multivariée                                                    | 21        |
| 3. Corrélations et associations                                                                  | 22        |
| 3.1. Variables numériques : Pearson et Spearman                                                  | 22        |

|                                                                                             |           |
|---------------------------------------------------------------------------------------------|-----------|
| 3.2. Variables catégorielles : tableaux croisés et V de Cramér . . . . .                    | 22        |
| 4. Agrégation : <b>groupby</b> et tableaux croisés dynamiques . . . . .                     | 23        |
| 5. Choisir une visualisation simple . . . . .                                               | 23        |
| 6. Profilage automatique des données . . . . .                                              | 24        |
| Exercices . . . . .                                                                         | 24        |
| <b>Introduction à l'entrepôt de données</b> . . . . .                                       | <b>27</b> |
| 1. Pourquoi un entrepôt de données ? . . . . .                                              | 27        |
| 1.1. Les systèmes opérationnels . . . . .                                                   | 27        |
| 1.2. La base analytique . . . . .                                                           | 27        |
| 1.3. Entrepôt, lac et datamart . . . . .                                                    | 28        |
| 2. Le modèle en étoile . . . . .                                                            | 28        |
| 2.1. La table de faits . . . . .                                                            | 28        |
| 2.2. Les tables de dimensions . . . . .                                                     | 28        |
| 2.3. Exemple de modèle de ventes . . . . .                                                  | 29        |
| 3. Les mesures et les indicateurs . . . . .                                                 | 29        |
| 4. Le flux ETL/ELT . . . . .                                                                | 30        |
| 5. Gouvernance et sécurité, sans complexité inutile . . . . .                               | 30        |
| Exercices . . . . .                                                                         | 31        |
| <b>Business Intelligence avec Power BI et Taipy</b> . . . . .                               | <b>33</b> |
| 1. Comprendre la BI . . . . .                                                               | 33        |
| 1.1. Du besoin à l'indicateur . . . . .                                                     | 33        |
| 1.2. Le parcours d'une solution BI . . . . .                                                | 33        |
| 1.3. Règles d'un tableau de bord débutant . . . . .                                         | 34        |
| 2. Power BI : une démarche structurée . . . . .                                             | 34        |
| 2.1. Étape 1 — Importer les sources . . . . .                                               | 34        |
| 2.2. Étape 2 — Transformer avec Power Query . . . . .                                       | 34        |
| 2.3. Étape 3 — Construire le modèle . . . . .                                               | 35        |
| 2.4. Étape 4 — Créer des mesures en DAX . . . . .                                           | 35        |
| 2.5. Étape 5 — Construire les visuels . . . . .                                             | 35        |
| 2.6. Étape 6 — Vérifier et partager . . . . .                                               | 36        |
| 3. Taipy : créer une application BI en Python . . . . .                                     | 36        |
| 3.1. Quand choisir Taipy ? . . . . .                                                        | 36        |
| 3.2. Un exemple Taipy minimal . . . . .                                                     | 36        |
| 3.3. Organiser une petite application . . . . .                                             | 37        |
| 4. Comparaison synthétique . . . . .                                                        | 37        |
| Exercices . . . . .                                                                         | 38        |
| <b>Cas pratique complet : analyser les ventes d'une petite chaîne de magasins</b> . . . . . | <b>40</b> |
| 1. Le besoin métier . . . . .                                                               | 40        |
| 1.1. Périmètre et définitions . . . . .                                                     | 40        |
| 2. Le jeu de données . . . . .                                                              | 41        |
| 2.1. Première lecture . . . . .                                                             | 41        |
| 3. Préparer les données . . . . .                                                           | 41        |
| 3.1. Dictionnaire minimal . . . . .                                                         | 41        |
| 3.2. Transformation . . . . .                                                               | 42        |
| 4. Calculer les indicateurs . . . . .                                                       | 42        |
| 4.1. Montants ligne par ligne . . . . .                                                     | 42        |
| 4.2. Par mois . . . . .                                                                     | 43        |
| 4.3. Par magasin et par catégorie . . . . .                                                 | 43        |
| 4.4. Moyenne et médiane des montants de lignes . . . . .                                    | 43        |
| 5. Construire le modèle analytique . . . . .                                                | 44        |
| 6. Concevoir la page Power BI . . . . .                                                     | 44        |

|                                         |           |
|-----------------------------------------|-----------|
| 7. Construire une vue Taipy . . . . .   | 44        |
| 8. Interpréter et communiquer . . . . . | 45        |
| Exercices . . . . .                     | 45        |
| <b>References</b>                       | <b>48</b> |

# Introduction à l'analyse de données

## 💡 Objectifs du chapitre

- À la fin de ce chapitre introductif, l'étudiant sera capable de :
- **Définir** l'analyse de données et la **situer** par rapport à la Data Science, la Business Intelligence (BI) et le Machine Learning ;
  - **Distinguer** les quatre types d'analyse : descriptive, diagnostique, prédictive et prescriptive ;
  - **Identifier** les grandes étapes du cycle de vie d'un projet d'analyse de données ;
  - **Identifier** les outils de base utilisés dans ce cours (Python, JupyterLab, `pandas`, `numpy`, `uv`) et les tendances récentes de l'écosystème.

## 1. Qu'est-ce que l'analyse de données ?

### 1.1. Définition

L'**analyse de données** (*Data Analysis*) désigne l'ensemble des démarches permettant d'inspecter, de nettoyer, de transformer et de modéliser statistiquement des données, dans le but d'en extraire des informations utiles, de soutenir une décision ou de valider une hypothèse.

## 💡 Analyse de données

**Définition 0.0.1.** L'analyse de données consiste à transformer des données brutes, souvent volumineuses et désorganisées, en **informations exploitables**, à travers une succession d'étapes de collecte, de nettoyage, d'exploration et de représentation.

Contrairement à ce que l'on pense parfois, l'essentiel du travail d'un analyste ne consiste pas à produire des graphiques, mais à **comprendre les données** : d'où elles viennent, ce qu'elles représentent réellement, quelles sont leurs limites et leurs biais. La visualisation n'intervient qu'en bout de chaîne, pour communiquer un résultat déjà établi.

### 1.2. Data Analysis, Data Science, Business Intelligence, Machine Learning : quelles frontières ?

Ces quatre termes sont souvent confondus. Ils partagent une matière première commune — la donnée — mais diffèrent par leurs objectifs et leurs méthodes.

TABLE 1 – Quatre disciplines complémentaires autour de la donnée

| Domaine                           | Question typique                               | Résultat produit                                         |
|-----------------------------------|------------------------------------------------|----------------------------------------------------------|
| <b>Business Intelligence (BI)</b> | « Que s'est-il passé, et où en sommes-nous ? » | Tableaux de bord, indicateurs (KPI) suivis dans le temps |

| Domaine                                   | Question typique                                                                | Résultat produit                                         |
|-------------------------------------------|---------------------------------------------------------------------------------|----------------------------------------------------------|
| <b>Analyse de données (Data Analysis)</b> | « Pourquoi cela s'est-il produit ?<br>Que peut-on en conclure ? »               | Rapports, visualisations,<br>recommandations argumentées |
| <b>Data Science</b>                       | « Que va-t-il probablement se<br>passer ? »                                     | Modèles statistiques et modèles de<br>Machine Learning   |
| <b>Machine Learning</b>                   | « Comment automatiser une<br>prédiction ou une décision à grande<br>échelle ? » | Un modèle entraîné, déployé en<br>production             |

### ⚠ Périimètre de ce cours

Ce module se concentre sur les deux premières colonnes de la Table 1 : la **préparation**, l'**exploration** et la **visualisation** des données. Les algorithmes de Machine Learning (régression, classification, clustering...) ne sont volontairement **pas traités ici** : ils font l'objet d'un module dédié. Une bonne partie du travail présenté dans ce cours reste néanmoins un prérequis indispensable à tout projet de Machine Learning.

En pratique, ces frontières sont poreuses : un même professionnel peut, selon les entreprises, être appelé *Data Analyst* et exercer des missions de *Data Scientist*, ou inversement. Ce qui compte est de comprendre **la nature de la question posée** plutôt que le titre du poste.

## 2. Les quatre types d'analyse de données

On distingue classiquement quatre niveaux d'analyse, de la simple observation du passé jusqu'à la recommandation d'action, chacun s'appuyant sur le précédent.

TABLE 2 – Les quatre types d'analyse de données

| Type d'analyse      | Question posée                       | Exemple                                                        |
|---------------------|--------------------------------------|----------------------------------------------------------------|
| <b>Descriptive</b>  | Que s'est-il passé ?                 | Le chiffre d'affaires du mois dernier par région               |
| <b>Diagnostic</b>   | Pourquoi cela s'est-il passé ?       | Pourquoi les ventes ont-elles chuté en mars dans le nord ?     |
| <b>Prédictive</b>   | Que va-t-il probablement se passer ? | Quel sera le chiffre d'affaires du mois prochain ?             |
| <b>Prescriptive</b> | Que devrait-on faire ?               | Quelle action marketing maximiserait les ventes du trimestre ? |

### 💡 Exemple filé : une chaîne de supermarchés marocaine

- **Descriptive** : « Les ventes de la région de Casablanca ont baissé de 12 % en mars par rapport à février. »
- **Diagnostic** : en croisant les ventes avec le calendrier et la météo, on découvre que la baisse coïncide avec des travaux routiers ayant réduit l'affluence dans deux magasins.
- **Prédictive** (*hors périmètre de ce cours, traité en Machine Learning*) : un modèle estime les ventes attendues pour le mois suivant compte tenu de la reprise du trafic.
- **Prescriptive** : sur la base du diagnostic, l'équipe décide de renforcer temporairement les promotions dans les magasins concernés.




FIGURE 1 – Les quatre types d'analyse de données

Ce cours se concentre principalement sur les analyses **descriptive** et **diagnostique** : elles reposent entièrement sur les techniques de préparation, d'exploration et de visualisation présentées dans les chapitres suivants, et ne nécessitent pas d'algorithme d'apprentissage automatique.

## 3. Les premiers indicateurs à connaître

Avant de construire un graphique ou un tableau de bord, il faut savoir décrire simplement les données. Une **observation** est une ligne du tableau (par exemple une commande) et une **variable** est une colonne (par exemple le montant de la commande). Une variable peut être :

- **qualitative** : une catégorie ou une étiquette, comme une ville ou un moyen de paiement ;
- **quantitative** : un nombre sur lequel on peut calculer, comme un prix, une quantité ou une durée ;
- **temporelle** : une date ou une période, que l'on peut ordonner dans le temps.

### 3.1. Compter et comparer

Le **nombre d'observations** indique la taille du jeu de données. Pour une catégorie, on utilise un effectif (combien de commandes à Casablanca ?) et une fréquence (quelle part des commandes vient de Casablanca ?).

Si 30 commandes sur 120 viennent de Casablanca :

$$\text{fréquence} = \frac{30}{120} = 0,25 = 25\%.$$

Pour comparer deux périodes, on peut calculer une variation :

$$\text{variation en \%} = \frac{\text{valeur finale} - \text{valeur initiale}}{\text{valeur initiale}} \times 100.$$

Une vente qui passe de 200 à 240 MAD a donc augmenté de  $\frac{240-200}{200} \times 100 = 20\%$ .

### 3.2. Résumer une variable numérique

Les indicateurs de tendance centrale et de dispersion seront utilisés tout au long du manuel :

| Indicateur                | Question à laquelle il répond                                  | Exemple d'interprétation                                                  |
|---------------------------|----------------------------------------------------------------|---------------------------------------------------------------------------|
| Moyenne                   | Quel serait le partage équitable du total ?                    | 10 commandes totalisent 2 000 MAD : moyenne = 200 MAD.                    |
| Médiane                   | Quelle valeur partage les observations en deux groupes égaux ? | La moitié des commandes vaut au plus la médiane.                          |
| Minimum / maximum         | Quelles sont les valeurs extrêmes observées ?                  | La commande la moins chère et la plus chère.                              |
| Quartiles $Q_1$ et $Q_3$  | Où se situent les 25 % et 75 % des observations ?              | 50 % des valeurs sont entre $Q_1$ et $Q_3$ .                              |
| Écart interquartile (IQR) | Quelle est la largeur de la moitié centrale ?                  | $IQR = Q_3 - Q_1$ .                                                       |
| Écart-type                | Les valeurs sont-elles plutôt proches de la moyenne ?          | Plus il est grand, plus les valeurs sont dispersées autour de la moyenne. |


La moyenne est calculée en additionnant les valeurs puis en divisant par leur nombre. La médiane nécessite de trier les valeurs : avec un nombre impair de valeurs, c'est la valeur du milieu ; avec un nombre pair, c'est la moyenne des deux valeurs centrales. Une valeur très élevée peut augmenter fortement la moyenne, mais elle influence beaucoup moins la médiane. C'est pourquoi les deux indicateurs doivent souvent être présentés ensemble.

```
resume = df["montant"].describe()
print(resume[["count", "mean", "50%", "min", "max"]])
```

La commande `describe()` fournit notamment l'effectif (`count`), la moyenne (`mean`), les quartiles (25%, 50%, 75%), le minimum et le maximum. Elle ne remplace pas l'interprétation : un indicateur doit toujours être accompagné de son unité, de sa période et de la population étudiée.

#### Un indicateur n'est pas une conclusion

Une moyenne de 250 MAD ne dit pas si les commandes sont toutes proches de 250 MAD ou si quelques très grosses commandes compensent beaucoup de petites commandes. Pour comprendre cela, on complète la moyenne par la médiane, les quartiles ou un graphique.



*Une exploration ou une visualisation décevante ramène souvent vers les étapes 2, 3 ou 4.*

FIGURE 2 – Le cycle de vie d'un projet d'analyse de données

## 4. Le cycle de vie d'un projet d'analyse de données

Un projet d'analyse de données suit une succession d'étapes, rarement linéaire, que l'on peut résumer ainsi :

1. **Cadrage** : formuler clairement la question métier à laquelle l'analyse doit répondre.
2. **Collecte** : rassembler les données nécessaires (bases de données, fichiers, API, web scraping...).
3. **Nettoyage** : traiter les valeurs manquantes, les valeurs aberrantes, les doublons et les incohérences — l'étape la plus chronophage en pratique.
4. **Transformation** : encoder, normaliser, recalculer certaines variables pour les rendre exploitables.
5. **Exploration (EDA)** : décrire statistiquement les données, en dégager des tendances, des corrélations, des anomalies.
6. **Visualisation et communication** : représenter graphiquement les résultats et les traduire en recommandations compréhensibles par un public non technique.

### i Repère

Ce découpage est proche du cadre **OSEMN** (*Obtain, Scrub, Explore, Model, iNterpret*), popularisé par la communauté Data Science. Nous l'adaptions ici en retirant l'étape de modélisation prédictive (« Model »), hors périmètre de ce cours, et en insistant davantage sur la communication des résultats.

Comme pour tout cycle de projet, ces étapes sont **itératives** : une exploration révélant un problème de qualité de données ramène généralement à l'étape de nettoyage, et une visualisation peu convaincante amène souvent à revisiter l'exploration.

## 5. Écosystème d'outils Python pour l'analyse de données

### 5.1. Bibliothèques cœur

Comme pour le Machine Learning, Python s'impose comme langage principal pour l'analyse de données, grâce à la richesse de son écosystème scientifique et à la lisibilité de sa syntaxe.

TABLE 3 – Bibliothèques Python cœur de ce cours

| Bibliothèque | Rôle                                                                                      |
|--------------|-------------------------------------------------------------------------------------------|
| pandas       | Manipulation de tableaux de données ( <b>DataFrame</b> ) : lecture, nettoyage, agrégation |
| numpy        | Calcul numérique et vectoriel sous-jacent à <b>pandas</b>                                 |
| matplotlib   | Bibliothèque de visualisation de référence, hautement personnalisable                     |
| seaborn      | Visualisation statistique construite sur <b>matplotlib</b> , orientée exploration rapide  |

### 5.2. Environnements de travail

Comme dans le reste de la formation, nous privilégions les **notebooks Jupyter** (JupyterLab, Google Colab) pour l'exploration interactive et la visualisation immédiate cellule par cellule, et **Visual Studio Code** pour consolider un script d'analyse reproductible destiné à être réexécuté ou partagé.

### 5.3. Gestion de projet avec uv

Comme pour les autres modules de la formation, les projets de ce cours sont organisés avec `uv`, qui centralise la gestion de l'environnement virtuel, des dépendances (`pyproject.toml`, `uv.lock`) et de l'exécution des scripts et notebooks. Se référer au module précédent pour le détail de son fonctionnement.

### 5.4. Tendances récentes de l'écosystème

#### ! Zoom sur les tendances actuelles

L'écosystème de l'analyse de données évolue rapidement. Sans remplacer les outils historiques présentés ci-dessus, plusieurs bibliothèques récentes gagnent en popularité et méritent d'être connues :

- **Polars** : une alternative à `pandas`, écrite en Rust, offrant des performances nettement supérieures sur de gros volumes de données grâce à l'exécution parallèle et à l'évaluation paresseuse (*lazy evaluation*).
- **DuckDB** : un moteur de base de données analytique embarqué, permettant d'exécuter des requêtes SQL directement sur des fichiers CSV ou Parquet, sans serveur, avec des performances proches d'un entrepôt de données.
- **Outils de profilage automatique** (`ydata-profiling`, `Sweetviz`) : génèrent en une commande un rapport exploratoire complet d'un jeu de données (statistiques, distributions, corrélations, valeurs manquantes) — voir le chapitre sur l'exploration des données.
- **Assistants d'analyse par IA générative** : des outils permettant d'interroger un `DataFrame` en langage naturel commencent à s'intégrer aux environnements de data analysis, sans se substituer à une compréhension rigoureuse des données par l'analyste.

Ces outils ne sont pas obligatoires dans ce cours, mais seront mentionnés ponctuellement à titre de complément, car ils représentent une évolution significative des pratiques professionnelles actuelles.

## 6. Les métiers de la donnée

TABLE 4 – Les principaux métiers autour de la donnée

| Métier                           | Mission principale                                                              | Compétences clés                                                    |
|----------------------------------|---------------------------------------------------------------------------------|---------------------------------------------------------------------|
| <b>Data Analyst</b>              | Explorer, visualiser et interpréter les données pour éclairer une décision      | SQL, <code>pandas</code> , visualisation, statistiques descriptives |
| <b>BI Analyst / BI Developer</b> | Construire et maintenir des tableaux de bord et indicateurs récurrents          | SQL, outils de BI (Power BI, Tableau), modélisation de données      |
| <b>Data Scientist</b>            | Concevoir des modèles statistiques et prédictifs                                | Statistique inférentielle, Machine Learning, programmation          |
| <b>Data Engineer</b>             | Construire et fiabiliser les pipelines d'acquisition et de stockage des données | Bases de données, orchestration, ingénierie logicielle              |

Ce cours prépare avant tout au cœur du métier de **Data Analyst**, tout en posant des bases indispensables aux trois autres profils.

### Auto-évaluation

Avant de passer au chapitre suivant, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je peux expliquer la différence entre analyse de données, Data Science, BI et Machine Learning.
- ☐ Je peux citer et illustrer les quatre types d'analyse de données.
- ☐ Je peux énumérer, dans l'ordre, les étapes du cycle de vie d'un projet d'analyse de données.
- ☐ Je connais au moins deux outils récents qui complètent **pandas** et **matplotlib**.

## Exercices

### Exercice 0.0.1 (Vrai ou Faux).

- a. La Business Intelligence répond principalement à la question « pourquoi ? ».
- b. Une analyse diagnostique s'appuie généralement sur une analyse descriptive préalable.
- c. Le Machine Learning est un prérequis indispensable pour produire une analyse descriptive.

### Solution de l'exercice Exercice 0.0.1

- a. **Faux.** La BI répond surtout à « que s'est-il passé, et où en sommes-nous ? » (analyse descriptive) ; c'est l'analyse diagnostique qui répond au « pourquoi ».
- b. **Vrai.** On ne peut expliquer une variation (diagnostic) sans l'avoir d'abord constatée et quantifiée (description).
- c. **Faux.** L'analyse descriptive repose sur des statistiques et des visualisations ; aucun modèle prédictif n'est nécessaire.

**Exercice 0.0.2** (Classer les questions). Pour chacune des questions suivantes, indiquez le type d'analyse correspondant (descriptive, diagnostique, prédictive ou prescriptive) :

- a. Combien de visiteurs le site web a-t-il reçus la semaine dernière ?
- b. Pourquoi le taux d'abandon de panier a-t-il augmenté en juillet ?
- c. Quelle campagne publicitaire faut-il privilégier pour la rentrée ?

### Solution de l'exercice Exercice 0.0.2

- a. **Descriptive** — simple constat chiffré.
- b. **Diagnostique** — recherche d'une cause à une variation observée.
- c. **Prescriptive** — recommandation d'action.

**Exercice 0.0.3** (Étude de cas courte). Une association marocaine de protection de l'environnement souhaite comprendre l'évolution du volume de déchets collectés dans trois villes sur les deux dernières années, puis identifier les facteurs expliquant les écarts entre villes.

- a. Quelles étapes du cycle de vie présenté en Figure 2 cette association devra-t-elle suivre ?
- b. À quel(s) type(s) d'analyse (Table 2) ce projet correspond-il ?

## 💡 Solution de l'exercice Exercice 0.0.3

- a. Cadrage de la question (comparer trois villes) → collecte des données de collecte de déchets → nettoyage (unités, doublons, données manquantes par ville/mois) → exploration statistique → visualisation comparative dans le temps et par ville.
- b. **Descriptive** (évolution des volumes) puis **diagnostique** (recherche des facteurs expliquant les écarts entre villes).

**Exercice 0.0.4** (Moyenne, médiane et fréquence). Les montants de cinq commandes sont : 80, 100, 100, 120 et 600 MAD.

- a. Calculez la moyenne et la médiane.
- b. Quel indicateur décrit le mieux une commande « typique » ? Pourquoi ?
- c. Quel est l'effectif et la fréquence des commandes d'au moins 100 MAD ?

## 💡 Solution de l'exercice Exercice 0.0.4

- a. La moyenne vaut  $(80 + 100 + 100 + 120 + 600)/5 = 200$  MAD. La médiane est la troisième valeur triée : **100 MAD**.
- b. La médiane est plus représentative : la commande de 600 MAD tire fortement la moyenne vers le haut.
- c. Quatre commandes sur cinq sont d'au moins 100 MAD : effectif **4**, fréquence **80 %**.

**Exercice 0.0.5** (Lire une variation). Le nombre de visiteurs d'un site passe de 2 000 en avril à 2 400 en mai, puis à 2 280 en juin.

- a. Calculez la variation en pourcentage entre avril et mai.
- b. Calculez la variation en pourcentage entre mai et juin.
- c. La baisse de mai à juin annule-t-elle entièrement la hausse précédente ?

## 💡 Solution de l'exercice Exercice 0.0.5

- a.  $(2400 - 2000)/2000 \times 100 = 20\%$ .
- b.  $(2280 - 2400)/2400 \times 100 = -5\%$ .
- c. Non. Le niveau de juin reste supérieur à avril :  $(2280 - 2000)/2000 \times 100 = 14\%$  environ.

**Exercice 0.0.6** (Identifier les indicateurs utiles). Pour chacune des questions, choisissez l'indicateur le plus directement utile : effectif, fréquence, moyenne, médiane, minimum/maximum ou IQR.

- a. Quelle part des clients utilise le paiement par carte ?
- b. Quel est le montant central des salaires ?
- c. Quelle est la largeur de la moitié centrale des durées de livraison ?
- d. Combien de commandes ont été enregistrées ?

## 💡 Solution de l'exercice Exercice 0.0.6

- a. **Fréquence** ; b. **médiane** ; c. **IQR** ; d. **effectif**.

**Exercice 0.0.7** (Reconnaître le type de variable). Classez les variables suivantes en qualitative, quantitative ou temporelle : `quartier`, `nombre_de_produits`, `date_commande`, `satisfaction` codée « faible / moyenne / élevée ».

💡 Solution de l'exercice Exercice 0.0.7

quartier est **qualitative nominale**; nombre\_de\_produits est **quantitative discrète**; date\_commande est **temporelle**; satisfaction est **qualitative ordinale**, car ses catégories possèdent un ordre.

**Exercice 0.0.8** (Choisir une analyse). Une responsable constate que les ventes sont plus faibles en août. Elle veut d'abord mesurer la baisse, puis comprendre si elle concerne seulement une région.

- a. Quel type d'analyse répond à la première question ?
- b. Quelle comparaison simple peut aider pour la seconde ?
- c. Pourquoi faut-il éviter de conclure à une cause avant d'avoir comparé les données ?

💡 Solution de l'exercice Exercice 0.0.8

- a. Une analyse **descriptive** : comparer les ventes d'août à celles d'une période de référence.
- b. Comparer les ventes par région et par mois, avec des effectifs, des totaux ou des moyennes.
- c. Une baisse peut coïncider avec plusieurs facteurs ; une comparaison permet d'abord de vérifier si le phénomène est général ou localisé. Elle ne prouve pas à elle seule une causalité.

# Préparation des données

## 💡 Objectifs du chapitre

À la fin de ce chapitre, l'étudiant sera capable de :

- **Identifier** les principales sources de collecte de données (bases de données, fichiers plats, API, web scraping) ;
- **Diagnostiquer** les problèmes de qualité d'un jeu de données (valeurs manquantes, aberrantes, dupliquées) ;
- **Appliquer** des stratégies adaptées de traitement des valeurs manquantes et aberrantes avec **pandas** ;
- **Transformer** des variables (encodage, normalisation, discrétisation) en vue de leur exploration ou de leur visualisation.

Si les données sont de mauvaise qualité, corrompues ou biaisées, aucune analyse — aussi soignée soit-elle — ne pourra produire de conclusions fiables (*Garbage In, Garbage Out*).

- Principe fondamental de l'analyse de données

Avant de pouvoir explorer ou visualiser un jeu de données, il faut d'abord le **rassembler** puis le **rendre exploitable**. Ce chapitre couvre les étapes 2, 3 et 4 du cycle de vie présenté au chapitre précédent (Figure 2) : où trouver les données, comment détecter et corriger leurs défauts, puis comment les transformer pour l'exploration et la visualisation.

## i Réflexe de débutant : connaître son tableau

Avant toute modification, conservez une copie du fichier original et rédigez un petit **dictionnaire de données**. Pour chaque colonne, notez son nom, sa signification, son unité, son type attendu et les valeurs possibles. Par exemple, **prix** peut être un nombre positif en MAD, tandis que **type\_bien** peut prendre les valeurs « appartement », « maison » ou « terrain ». Ce dictionnaire évite de corriger une valeur qui était en réalité valide.

## 1. Collecte de données

### 1.1. Les bases de données

La source la plus courante en entreprise reste la base de données interne :

- **relationnelle (SQL)** : données organisées en tables reliées par des clés (PostgreSQL, MySQL, SQL Server), interrogées avec le langage **SQL** ;
- **non-relationnelle (NoSQL)** : données stockées sous une forme plus flexible — documents JSON (MongoDB), paires clé-valeur (Redis) — adaptées à des données peu structurées ou à très grande échelle.

**pandas** permet de charger directement le résultat d'une requête SQL dans un **DataFrame** :

```
import pandas as pd
import sqlite3

connexion = sqlite3.connect("ventes.db")
df = pd.read_sql("SELECT * FROM transactions WHERE annee = 2025", connexion)
```

## 1.2. Les fichiers plats et formats de données

En dehors des bases de données, les données sont fréquemment échangées sous forme de fichiers :

TABLE 1 – Principaux formats de données rencontrés en analyse de données

| Format               | Caractéristiques                                                 | Lecture avec <code>pandas</code> |
|----------------------|------------------------------------------------------------------|----------------------------------|
| <b>CSV</b>           | Texte tabulaire, très répandu, lisible par un humain             | <code>pd.read_csv()</code>       |
| <b>JSON</b>          | Structure hiérarchique (objets imbriqués), courant pour les API  | <code>pd.read_json()</code>      |
| <b>Excel (.xlsx)</b> | Tableur, souvent utilisé en entreprise                           | <code>pd.read_excel()</code>     |
| <b>Parquet</b>       | Format binaire colonnaire, compressé, optimisé pour l'analytique | <code>pd.read_parquet()</code>   |

### ! Zoom sur les tendances : le format Parquet

Contrairement au CSV, le format **Parquet** stocke les données par colonne plutôt que par ligne. Cela permet de ne lire que les colonnes réellement nécessaires à une analyse, de bénéficier d'une compression efficace et de conserver les types de données (un entier reste un entier, pas une chaîne de caractères à réinterpréter). Il est aujourd'hui privilégié pour les jeux de données volumineux, et s'utilise nativement avec `pandas`, `Polars` ou `DuckDB`.

## 1.3. Les API

Une **API** (*Application Programming Interface*) permet d'obtenir des données structurées de façon normalisée, sans avoir à analyser du HTML :

- les **API REST**, les plus répandues, où chaque ressource est accessible via une URL et une méthode HTTP (GET, POST...), avec une réponse généralement au format JSON ;
- les **API GraphQL**, plus récentes, qui permettent au client de préciser exactement les champs souhaités en une seule requête.

```
import requests
import pandas as pd

reponse = requests.get("https://api.exemple.org/ventes?annee=2025")
df = pd.json_normalize(reponse.json()["resultats"])
```

## 1.4. Le web scraping

Lorsque les données ne sont disponibles que sur des pages web, on recourt au **web scraping** : l'extraction automatisée d'informations à partir du code HTML. Les bibliothèques Python de référence sont **BeautifulSoup** (analyse d'une page unique) et **Scrapy** (collecte à grande échelle, avec gestion de la pagination et des files d'attente).

### ⚠ Éthique et légalité du web scraping

Avant de collecter des données sur un site, il convient de vérifier son fichier **robots.txt**, ses conditions générales d'utilisation, ainsi que le cadre réglementaire applicable à la protection des données personnelles (RGPD, ou la loi marocaine 09-08), en particulier si des données à caractère personnel sont concernées.

## 1.5. Open data et capteurs / IoT

Deux autres sources méritent d'être mentionnées :

- les **portails d'open data** (données publiques mises à disposition par des institutions, ex. données démographiques, économiques ou climatiques) ;
- les **capteurs et objets connectés (IoT)**, qui génèrent des flux de données en continu (température, géolocalisation, fréquentation), souvent collectés via des files de messages (ex. MQTT, Kafka) avant d'être stockés pour l'analyse.

## 2. Nettoyage des données

Une fois collectées, les données contiennent presque toujours des imperfections. Le nettoyage est l'étape la plus chronophage d'un projet d'analyse — souvent estimée à 60-80 % du temps réel passé sur un projet.

Un nettoyage fiable vérifie au moins cinq dimensions :

1. **complétude** : les informations importantes sont-elles présentes ?
2. **validité** : les valeurs respectent-elles les règles attendues (un prix positif, une date valide) ?
3. **unicité** : une même observation n'est-elle pas enregistrée deux fois ?
4. **cohérence** : les colonnes et les unités sont-elles compatibles entre elles ?
5. **actualité** : les dates couvrent-elles la période utile à la question ?

Il faut garder une trace de chaque correction : colonne concernée, règle appliquée, nombre de lignes modifiées et justification. Cette documentation permet de revenir en arrière et d'expliquer les résultats.

### 2.1. Les valeurs manquantes

Une valeur manquante peut avoir des origines très différentes, ce qui conditionne la stratégie à adopter :

TABLE 2 – Typologie des valeurs manquantes

| Type                                                | Signification                                                | Exemple                                                         |
|-----------------------------------------------------|--------------------------------------------------------------|-----------------------------------------------------------------|
| <b>MCAR</b> ( <i>Missing Completely At Random</i> ) | L'absence ne dépend d'aucune variable, ni observée ni cachée | Un capteur tombe en panne aléatoirement                         |
| <b>MAR</b> ( <i>Missing At Random</i> )             | L'absence dépend d'une autre variable observée               | Les hommes répondent moins souvent à une question sur le revenu |

| Type                                         | Signification                                     | Exemple                                                    |
|----------------------------------------------|---------------------------------------------------|------------------------------------------------------------|
| <b>MNAR</b> ( <i>Missing Not At Random</i> ) | L'absence dépend de la valeur manquante elle-même | Les personnes aux revenus très élevés refusent de répondre |

Ces trois étiquettes servent surtout à réfléchir à la cause d'une absence. Il n'est pas demandé de réaliser un test statistique pour les distinguer dans ce cours : l'étudiant doit surtout éviter d'imputer automatiquement sans comprendre ce que signifie la valeur manquante.

Avec **pandas**, on détecte et on traite les valeurs manquantes ainsi :

```
# Détection
df.isna().sum()                # nombre de valeurs manquantes par colonne
df.isna().mean().round(2) * 100 # pourcentage de valeurs manquantes

# Suppression
df.dropna(subset=["prix"])      # supprime les lignes sans prix

# Imputation
df["surface"] = df["surface"].fillna(df["surface"].median())
df["quartier"] = df["quartier"].fillna("Non renseigné")
```

💡 Comment choisir entre suppression et imputation ?

- Si la proportion de valeurs manquantes est **faible** (quelques pourcents) et que le mécanisme semble MCAR, la **suppression** des lignes concernées est souvent acceptable.
- Si la proportion est **élevée**, ou si l'absence porte sur une variable centrale de l'analyse, on préfère une **imputation** (moyenne, médiane, mode, ou une valeur explicite comme « Non renseigné »), en gardant à l'esprit qu'elle introduit un biais qu'il faut documenter.

## 2.2. Les valeurs aberrantes (*outliers*)

Une valeur aberrante est une observation qui s'écarte fortement du reste de la distribution. Deux méthodes usuelles permettent de les détecter :

- la méthode du **score Z**, qui signale une observation aberrante lorsque  $|z| = \left| \frac{x - \bar{x}}{\sigma} \right| > 3$  ;
- la méthode de l'**écart interquartile (IQR)**, plus robuste aux distributions asymétriques : on considère comme aberrante toute valeur en dehors de l'intervalle  $[Q_1 - 1,5 \times IQR, Q_3 + 1,5 \times IQR]$ , avec  $IQR = Q_3 - Q_1$ .

```
q1, q3 = df["prix"].quantile([0.25, 0.75])
iqr = q3 - q1
borne_basse, borne_haute = q1 - 1.5 * iqr, q3 + 1.5 * iqr

aberrants = df[(df["prix"] < borne_basse) | (df["prix"] > borne_haute)]
```

La **boîte à moustaches** (*boxplot*), présentée au chapitre suivant sur la visualisation, est l'outil graphique privilégié pour repérer visuellement ces valeurs.

⚠ Une valeur aberrante n'est pas toujours une erreur

Avant de supprimer une valeur aberrante, il faut se demander si elle correspond à une **erreur de saisie** (à corriger ou supprimer) ou à un **phénomène réel mais rare** (par exemple une vente exceptionnelle), qu'il peut être pertinent de conserver, voire d'étudier spécifiquement.

## 2.3. Doublons et incohérences

```
df.duplicated().sum()          # nombre de lignes strictement dupliquées
df = df.drop_duplicates()

df["ville"] = df["ville"].str.strip().str.title()  # espaces superflus, casse
df["date"] = pd.to_datetime(df["date"], errors="coerce")  # type de données cohérent
```

Les incohérences les plus fréquentes concernent la **casse** et les **espaces superflus** dans les chaînes de caractères (« casablanca » vs « Casablanca »), les **types de données** mal interprétés (une date lue comme texte), et les **unités hétérogènes** (des prix exprimés tantôt en MAD, tantôt en euros).

## 2.4. Vers une démarche de qualité des données

! Zoom sur les tendances : la validation systématique de la qualité

Sur des projets d'analyse récurrents (tableaux de bord alimentés quotidiennement, par exemple), il devient risqué de vérifier la qualité des données « à l'œil » à chaque exécution. Des bibliothèques comme **Great Expectations** permettent de définir des règles de validation explicites (« la colonne **prix** doit toujours être positive », « la colonne **date** ne doit jamais être manquante ») et de les exécuter automatiquement à chaque nouvelle collecte de données, afin de détecter une dérive de qualité avant qu'elle n'affecte l'analyse.

# 3. Transformation des données

Une fois nettoyées, les données doivent souvent être reformatées avant l'exploration ou la visualisation.

## 3.1. Encodage des variables catégorielles

De nombreux outils statistiques et graphiques manipulent plus facilement des valeurs numériques que du texte. On distingue deux stratégies principales :

- l'**encodage ordinal**, adapté aux catégories qui possèdent un ordre naturel (ex. « Faible » < « Moyen » < « Élevé ») ;
- l'**encodage one-hot** (variables indicatrices), adapté aux catégories sans ordre (ex. les quartiers d'une ville), qui crée une colonne binaire par catégorie.

```
# Encodage ordinal
ordre = {"Faible": 0, "Moyen": 1, "Élevé": 2}
df["niveau_encode"] = df["niveau"].map(ordre)

# Encodage one-hot
df_encode = pd.get_dummies(df, columns=["quartier"])
```

#### Note

L'encodage détaillé des variables (avec `scikit-learn`, gestion des catégories rares, etc.) sera approfondi dans le module de Machine Learning. Dans ce cours, il est surtout utile pour faciliter certains graphiques et calculs de corrélation présentés au chapitre suivant.

## 3.2. Normalisation et standardisation

Lorsque plusieurs variables numériques ont des échelles très différentes (ex. une surface en  $m^2$  et un prix en millions de MAD), il est parfois utile de les ramener à une échelle comparable, notamment pour certaines visualisations combinées :

- la **normalisation min-max** ramène chaque valeur dans l'intervalle  $[0, 1]$  :  $x' = \frac{x - x_{min}}{x_{max} - x_{min}}$  ;
- la **standardisation** (score Z) centre la variable autour de 0 avec un écart-type de 1 :  $x' = \frac{x - \bar{x}}{\sigma}$ .

```
df["prix_norm"] = (df["prix"] - df["prix"].min()) / (df["prix"].max() - df["prix"].min())
df["prix_standard"] = (df["prix"] - df["prix"].mean()) / df["prix"].std()
```

## 3.3. Discrétisation (*binning*)

La discrétisation consiste à transformer une variable numérique continue en catégories, souvent utile pour simplifier une visualisation (par exemple des tranches d'âge plutôt qu'un âge exact) :

```
df["tranche_age"] = pd.cut(
    df["age"],
    bins=[0, 18, 35, 60, 120],
    labels=["Mineur", "Jeune adulte", "Adulte", "Senior"]
)
```

## 3.4. Quelques transformations usuelles supplémentaires

- **Extraction de composantes temporelles** : à partir d'une colonne `date`, on extrait fréquemment l'année, le mois, le jour de semaine (`df["date"].dt.month`), utiles pour l'exploration de séries temporelles.
- **Agrégats dérivés** : création de nouvelles colonnes résumant une information (ex. le prix au mètre carré = `prix / surface`), qui facilitent grandement l'exploration et la comparaison.

#### Ne pas transformer sans objectif

Une transformation n'est pas automatiquement une amélioration. Par exemple, remplacer toutes les valeurs manquantes par zéro change la signification de la variable : « absence d'information » devient « valeur nulle ». Avant chaque transformation, demandez-vous quelle question elle facilite et si son effet sera documenté.

**i** Auto-évaluation

Avant de passer au chapitre suivant, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je sais citer trois sources possibles de collecte de données et un cas d'usage pour chacune.
- ☐ Je sais distinguer les valeurs manquantes MCAR, MAR et MNAR et adapter ma stratégie en conséquence.
- ☐ Je sais détecter des valeurs aberrantes avec la méthode de l'IQR.
- ☐ Je sais choisir entre encodage ordinal et one-hot selon la nature d'une variable catégorielle.

## Exercices

**Exercice 0.0.1** (Choisir une stratégie de traitement des valeurs manquantes). Un jeu de données de candidatures à un emploi comporte une colonne `salaire_souhaite` manquante pour 40 % des lignes. Une analyse rapide montre que les candidats les plus expérimentés (souvent plus exigeants sur le salaire) sont surreprésentés parmi les valeurs manquantes.

- a. À quel type de valeur manquante (Table 2) correspond cette situation ?
- b. Recommanderiez-vous une suppression ou une imputation ? Justifiez.

## 💡 Solution de l'exercice Exercice 0.0.1

- a. Il s'agit d'un cas **MNAR** : l'absence de réponse dépend de la valeur elle-même (les candidats avec un salaire souhaité élevé répondent moins).
- b. Ni la suppression pure ni une imputation par la moyenne ne sont satisfaisantes ici, car elles biaiseraient l'analyse à la baisse. Il est préférable de **documenter explicitement** cette non-réponse (par exemple une catégorie « Non communiqué ») plutôt que de l'imputer silencieusement, et d'en tenir compte dans l'interprétation des résultats.

**Exercice 0.0.2** (Détection d'outliers). Pour une variable `prix` avec  $Q_1 = 200\,000$  et  $Q_3 = 450\,000$  (en MAD), calculez les bornes de détection des valeurs aberrantes selon la méthode de l'IQR.

## 💡 Solution de l'exercice Exercice 0.0.2

$$IQR = 450\,000 - 200\,000 = 250\,000.$$

- Borne basse :  $200\,000 - 1,5 \times 250\,000 = -175\,000$  (donc, en pratique, aucune valeur basse ne sera jamais considérée comme aberrante ici, un prix ne pouvant être négatif).
- Borne haute :  $450\,000 + 1,5 \times 250\,000 = 825\,000$ .

Tout bien affiché à plus de 825 000 MAD serait donc signalé comme potentiellement aberrant.

**Exercice 0.0.3** (Encodage). Pour chacune des variables suivantes, indiquez si un encodage **ordinal** ou **one-hot** est le plus adapté, et pourquoi :

- a. Le niveau d'étude (« Bac », « Bac+2 », « Bac+3 », « Bac+5 ») ;
- b. La couleur préférée d'un client (« Rouge », « Bleu », « Vert »).

💡 Solution de l'exercice Exercice 0.0.3

- a. **Encodage ordinal** : les niveaux d'étude possèdent un ordre naturel croissant.
- b. **Encodage one-hot** : les couleurs n'ont pas d'ordre logique entre elles ; leur attribuer un ordre arbitraire introduirait une fausse relation numérique.

**Exercice 0.0.4** (Diagnostic de qualité). Un fichier de ventes contient 1 000 lignes. La colonne **date** comporte 20 valeurs manquantes, **prix** contient 5 valeurs négatives et 12 lignes sont des doublons exacts.

- a. Quel pourcentage de dates est manquant ?
- b. Quel problème doit être vérifié en priorité avant de calculer le chiffre d'affaires ?
- c. Les doublons doivent-ils être supprimés automatiquement ? Justifiez.

💡 Solution de l'exercice Exercice 0.0.4

- a.  $20/1000 \times 100 = 2\%$ .
- b. Les **prix négatifs**, car ils rendent le total incohérent et peuvent signaler une règle métier particulière (remboursement) ou une erreur.
- c. Non. Il faut vérifier si les lignes sont réellement identiques ou si elles représentent deux transactions légitimes saisies avec les mêmes valeurs. Une suppression aveugle pourrait supprimer de vraies ventes.

**Exercice 0.0.5** (Choisir une stratégie d'imputation). Associez chaque situation à une stratégie raisonnable : supprimer quelques lignes, utiliser la médiane, créer la catégorie « Non renseigné » ou ne pas imputer sans investigation.

- a. 1 % des lignes n'ont pas de surface, et la surface est numérique.
- b. 35 % des lignes n'ont pas de quartier.
- c. Une date manquante empêche de savoir à quelle période appartient une vente.
- d. Une variable **remise** a 2 % de valeurs manquantes dans une distribution très asymétrique.

💡 Solution de l'exercice Exercice 0.0.5

- a. **Médiane** (ou suppression des rares lignes si elles ne sont pas centrales), après vérification.
- b. « **Non renseigné** », afin de ne pas perdre un tiers du jeu de données.
- c. **Ne pas imputer sans investigation** : il faut retrouver la date dans la source ou exclure la vente d'une analyse temporelle.
- d. **Médiane** plutôt que moyenne, car elle est plus robuste à l'asymétrie ; la décision doit être documentée.

**Exercice 0.0.6** (Calculer une normalisation min-max). Une variable **score** varie de 20 à 80. Calculez la valeur normalisée d'un score égal à 50 avec :

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

Que signifie le résultat ?

💡 Solution de l'exercice Exercice 0.0.6

$x' = (50 - 20)/(80 - 20) = 30/60 = 0,5$ . Le score 50 se situe au milieu de l'intervalle observé. La normalisation ne signifie pas que 50 est la moyenne : elle indique sa position entre le minimum et le maximum.

**Exercice 0.0.7** (Unités et cohérence). Une colonne **distance** contient les valeurs 5, 12 et 8 pour trois trajets, mais le dictionnaire indique que certaines lignes sont en kilomètres et d'autres en mètres.

- Pourquoi est-il dangereux de calculer une moyenne directement ?
- Quelle action doit être réalisée avant l'analyse ?
- Est-ce un problème de valeur manquante, de validité ou de cohérence ?

 Solution de l'exercice Exercice 0.0.7

- Les nombres n'ont pas la même unité : la moyenne mélangerait des grandeurs incomparables.
- Identifier l'unité de chaque ligne puis convertir toutes les valeurs dans une unité commune, par exemple le kilomètre.
- C'est principalement un problème de **cohérence** ; certaines valeurs peuvent aussi être invalides si leur unité est inconnue.

**Exercice 0.0.8** (Discretisation et interprétation). On regroupe les âges selon les intervalles  $[0,18[$ ,  $[18,35[$ ,  $[35,60[$  et  $[60,120]$ .

- Dans quelle classe place-t-on les âges 18, 34, 35 et 60 ?
- Quel avantage apporte cette transformation pour un tableau de bord ?
- Quel risque faut-il signaler ?

 Solution de l'exercice Exercice 0.0.8

- 18 et 34 vont dans  $[18,35[$ , 35 dans  $[35,60[$ , et 60 dans  $[60,120]$ .
- Elle simplifie la lecture et permet de comparer des groupes d'âge.
- Elle fait perdre de la précision : deux personnes de 18 et 34 ans sont dans le même groupe malgré un écart important. Les bornes doivent donc être documentées.

# Exploration des données

## 💡 Objectifs du chapitre

À la fin de ce chapitre, l'étudiant sera capable de :

- **Calculer et interpréter** les principales statistiques descriptives (tendance centrale, dispersion, forme) ;
- **Distinguer** l'analyse univariée, bivariée et multivariée ;
- **Mesurer** une corrélation ou une association entre deux variables et en connaître les limites ;
- **Construire** des tableaux d'agrégation (**groupby**, tableaux croisés dynamiques) pour résumer un jeu de données ;
- **Utiliser** un outil de profilage automatique pour accélérer une première exploration.

L'**analyse exploratoire de données** (*Exploratory Data Analysis*, EDA), popularisée par le statisticien John Tukey, consiste à examiner un jeu de données déjà nettoyé afin d'en dégager les tendances principales, les relations entre variables et les éventuelles anomalies restantes — avant toute conclusion définitive ou toute visualisation destinée à un public externe.

## 1. Statistiques descriptives

### 1.1. Tendance centrale

TABLE 1 – Indicateurs de tendance centrale

| Indicateur     | Définition                                               | Sensibilité aux valeurs extrêmes                        |
|----------------|----------------------------------------------------------|---------------------------------------------------------|
| <b>Moyenne</b> | Somme des valeurs divisée par leur nombre                | Élevée                                                  |
| <b>Médiane</b> | Valeur qui sépare la distribution en deux moitiés égales | Faible                                                  |
| <b>Mode</b>    | Valeur la plus fréquente                                 | Faible (mais peu informatif pour une variable continue) |

```
df["prix"].mean()
df["prix"].median()
df["quartier"].mode()[0]
```

#### ⚠️ Moyenne ou médiane ?

Sur une distribution fortement asymétrique — typiquement les salaires ou les prix de l'immobilier — la moyenne peut être fortement tirée vers le haut par quelques valeurs extrêmes. La **médiane** donne alors une image plus représentative de la « valeur typique ».

## 1.2. Dispersion

- l'**écart-type** ( $\sigma$ ) et la **variance** ( $\sigma^2$ ) mesurent l'écart moyen à la moyenne ;
- l'**écart interquartile** ( $IQR = Q_3 - Q_1$ ), déjà rencontré au chapitre précédent, mesure la dispersion de la moitié centrale des données, de façon robuste aux valeurs extrêmes ;
- l'**étendue** (maximum – minimum) donne une idée rapide, mais très sensible aux valeurs aberrantes.

```
df["prix"].std()
df["prix"].var()
df["prix"].quantile([0.25, 0.5, 0.75])
```

Pour un petit tableau, on peut calculer les indicateurs à la main. Pour les valeurs 2, 4, 4, 6, 9, la moyenne est  $25/5 = 5$  et la médiane est 4. L'étendue vaut  $9 - 2 = 7$ . Les quartiles dépendent de la convention de calcul utilisée par l'outil ; dans un cours débutant, l'important est de préciser la convention et de comparer les résultats avec la même méthode.

L'écart-type est exprimé dans la même unité que la variable, contrairement à la variance. Il est utile pour décrire la dispersion, mais il est sensible aux valeurs extrêmes. L'IQR est souvent plus facile à interpréter pour une distribution asymétrique. Le **coefficient de variation**, défini par  $\sigma/\bar{x}$  lorsque la moyenne est positive et non nulle, permet parfois de comparer la dispersion relative de variables ayant des échelles différentes ; il est présenté ici comme un repère et non comme un indicateur obligatoire.

### i Priorité pour débiter

Les indicateurs indispensables sont l'effectif, la moyenne, la médiane, le minimum, le maximum, les quartiles et l'écart-type ou l'IQR. L'asymétrie, l'aplatissement et le coefficient de variation sont des compléments : il suffit d'en comprendre l'idée et de savoir quand demander une explication supplémentaire.

## 1.3. Forme de la distribution

Deux indicateurs complètent la description d'une distribution :

- l'**asymétrie** (*skewness*) : une valeur positive indique une distribution étalée vers la droite (queue de valeurs élevées), une valeur négative vers la gauche ;
- l'**aplatissement** (*kurtosis*) : indique si la distribution comporte davantage de valeurs extrêmes qu'une distribution normale.

```
df["prix"].skew()
df["prix"].kurt()
```

La méthode `describe()` de `pandas` regroupe l'essentiel de ces indicateurs en une seule commande :

```
df.describe()
```

## 2. Analyse univariée, bivariable et multivariée

TABLE 2 – Les trois niveaux de l’analyse exploratoire

| Niveau d’analyse   | Nombre de variables étudiées simultanément | Exemple                                  |
|--------------------|--------------------------------------------|------------------------------------------|
| <b>Univariée</b>   | Une seule                                  | Distribution des prix de vente           |
| <b>Bivariée</b>    | Deux                                       | Relation entre surface et prix           |
| <b>Multivariée</b> | Trois ou plus                              | Relation entre surface, quartier et prix |

L’**analyse univariée** décrit une variable isolément (statistiques descriptives, distribution). L’**analyse bivariée** cherche une relation entre deux variables — par exemple à l’aide d’un tableau croisé pour deux variables catégorielles, ou d’un coefficient de corrélation pour deux variables numériques. L’**analyse multivariée** étend cette logique à plusieurs variables simultanément, souvent à l’aide de tableaux d’agrégation ou de visualisations combinant plusieurs dimensions (couleur, taille, facettes), présentées au chapitre suivant.

### 3. Corrélations et associations

#### 3.1. Variables numériques : Pearson et Spearman

- le **coefficient de corrélation de Pearson** ( $r$ , entre  $-1$  et  $1$ ) mesure l’intensité d’une relation **linéaire** entre deux variables numériques ;
- le **coefficient de corrélation de Spearman** mesure une relation **monotone** (pas nécessairement linéaire), en travaillant sur les rangs des valeurs plutôt que sur les valeurs elles-mêmes — plus robuste aux valeurs aberrantes.

```
df[["surface", "prix"]].corr(method="pearson")
df[["surface", "prix"]].corr(method="spearman")
```

#### ⚠ Corrélation n’est pas causalité

Une corrélation élevée entre deux variables ne signifie pas que l’une provoque l’autre : elle peut résulter d’une **variable cachée** commune, ou d’une pure coïncidence statistique. Un exemple classique est la corrélation observée entre les ventes de glaces et le nombre de noyades : les deux augmentent en été, sans lien de cause à effet direct entre elles.

#### 3.2. Variables catégorielles : tableaux croisés et V de Cramér

Pour deux variables catégorielles, on utilise un **tableau croisé** (*crosstab*), éventuellement complété par le **V de Cramér**, qui résume en un seul indicateur (entre 0 et 1) l’intensité de l’association :

```
tableau_croise = pd.crosstab(df["quartier"], df["type_bien"])
```

## 4. Agrégation : *groupby* et tableaux croisés dynamiques

L'outil central de l'exploration multivariée avec **pandas** est la méthode `groupby()`, qui permet de calculer un indicateur pour chaque sous-groupe d'une variable catégorielle :

```
df.groupby("quartier")["prix"].mean().sort_values(ascending=False)

df.groupby(["quartier", "type_bien"]).agg(
    prix_moyen=("prix", "mean"),
    nombre_biens=("prix", "count")
)
```

Le **tableau croisé dynamique** (*pivot table*) offre une présentation plus lisible lorsque l'on croise deux dimensions catégorielles avec une mesure numérique :

```
pd.pivot_table(
    df,
    values="prix",
    index="quartier",
    columns="type_bien",
    aggfunc="mean"
)
```

Ces deux outils constituent la base de la quasi-totalité des tableaux de bord et des rapports produits par un Data Analyst.

## 5. Choisir une visualisation simple

Les statistiques répondent à des questions numériques ; les graphiques rendent les formes et les comparaisons plus faciles à voir. Pour débiter, on peut retenir les associations suivantes :

| Question                                             | Graphique conseillé | Ce que l'on observe                         |
|------------------------------------------------------|---------------------|---------------------------------------------|
| Quelle est la répartition d'une variable numérique ? | Histogramme         | Forme, concentration et asymétrie           |
| Y a-t-il des valeurs atypiques ?                     | Boîte à moustaches  | Médiane, quartiles et valeurs éloignées     |
| Comment une valeur évolue-t-elle dans le temps ?     | Courbe              | Tendance, saisonnalité et ruptures          |
| Comment comparer des catégories ?                    | Barres              | Effectifs, sommes ou moyennes par catégorie |
| Deux variables numériques évoluent-elles ensemble ?  | Nuage de points     | Relation, groupes et valeurs atypiques      |

Un graphique ne doit pas seulement être « joli ». Son titre doit préciser la mesure, l'unité et la période ; ses axes doivent être lisibles ; la source et les filtres importants doivent être connus. Pour comparer des catégories, l'effectif et la moyenne ne racontent pas la même histoire : une catégorie peut avoir une moyenne élevée avec très peu d'observations.

## 6. Profilage automatique des données

Sur un nouveau jeu de données, il est souvent utile d'obtenir rapidement une vue d'ensemble avant de se lancer dans une exploration manuelle détaillée.

### ! Zoom sur les tendances : rapports d'exploration automatisés

Des bibliothèques comme `ydata-profiling` (anciennement `pandas-profiling`) ou `Sweetviz` génèrent, en une seule instruction, un rapport HTML complet : statistiques descriptives par variable, distributions, valeurs manquantes, corrélations entre variables, alertes de qualité (variables constantes, fortement corrélées, etc.).

```
from ydata_profiling import ProfileReport

profil = ProfileReport(df, title="Exploration du jeu de données")
profil.to_file("rapport_exploration.html")
```

Ces outils ne remplacent pas le raisonnement de l'analyste — ils accélèrent la première prise de contact avec un jeu de données et aident à repérer rapidement les points nécessitant une attention particulière, avant une exploration ciblée avec les techniques présentées dans ce chapitre.

### i Auto-évaluation

Avant de passer au chapitre suivant, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je sais expliquer pourquoi la médiane est parfois préférable à la moyenne.
- ☐ Je sais distinguer une analyse univariée, bivariée et multivariée avec un exemple pour chacune.
- ☐ Je sais expliquer pourquoi une forte corrélation n'implique pas une relation de cause à effet.
- ☐ Je sais construire un tableau croisé dynamique avec `pandas`.

## Exercices

**Exercice 0.0.1** (Interpréter des statistiques descriptives). Pour une variable `revenu_mensuel` (en MAD), on obtient : moyenne = 8 500, médiane = 6 200, écart-type = 5 400, asymétrie (*skewness*) = 2,3.

- a. Que suggère l'écart important entre la moyenne et la médiane ?
- b. Que confirme la valeur positive et élevée de l'asymétrie ?

### 💡 Solution de l'exercice Exercice 0.0.1

- a. Un écart important entre une moyenne nettement supérieure à la médiane suggère la présence de quelques revenus très élevés qui tirent la moyenne vers le haut, sans être représentatifs de la majorité des observations.
- b. Une asymétrie positive et élevée confirme une distribution étalée vers la droite (une « longue traîne » de hauts revenus), cohérente avec l'écart observé entre moyenne et médiane.

**Exercice 0.0.2** (Choisir le bon coefficient de corrélation). Pour chacune des situations suivantes, indiquez s'il est préférable d'utiliser Pearson ou Spearman :

- a. La relation entre l'ancienneté d'un employé (en années) et son salaire, globalement croissante mais pas forcément linéaire.

- b. La relation entre la taille et le poids d'un ensemble d'individus adultes, approximativement linéaire.

💡 Solution de l'exercice Exercice 0.0.2

- a. **Spearman**, car la relation est monotone (croissante) sans être nécessairement linéaire ; Spearman capte ce type de relation même s'il n'est pas de forme parfaitement linéaire.  
b. **Pearson**, adapté à une relation linéaire entre deux variables numériques.

**Exercice 0.0.3** (Construire un plan d'exploration). On dispose d'un jeu de données de transactions d'un site e-commerce marocain, avec les colonnes suivantes : `date_commande`, `categorie_produit`, `prix`, `region_client`, `moyen_paiement`.

Proposez, pour ce jeu de données, un exemple concret d'analyse univariée, un exemple d'analyse bivariée et un exemple d'analyse multivariée, en vous appuyant sur ces colonnes.

💡 Solution de l'exercice Exercice 0.0.3

- **Univariée** : distribution du `prix` des commandes (moyenne, médiane, dispersion).
- **Bivariée** : prix moyen selon la `categorie_produit` (via `groupby`).
- **Multivariée** : prix moyen croisé par `region_client` et `moyen_paiement` (via un tableau croisé dynamique), permettant de voir si certaines régions privilégient certains moyens de paiement pour des achats plus ou moins coûteux.

**Exercice 0.0.4** (Calculer des indicateurs simples). Les durées de livraison, en jours, sont : 2, 3, 3, 4, 8.

- a. Calculez la moyenne, la médiane et l'étendue.  
b. Quel indicateur est le moins influencé par la durée de 8 jours ?  
c. Quelle question supplémentaire poseriez-vous avant de conclure que le service est lent ?

💡 Solution de l'exercice Exercice 0.0.4

- a. Moyenne =  $(2 + 3 + 3 + 4 + 8)/5 = 4$  jours ; médiane = **3 jours** ; étendue =  $8 - 2 = 6$  jours.  
b. La **médiane**.  
c. Il faut connaître le nombre total de livraisons, la période, la région et la proportion de livraisons de 8 jours : une seule valeur extrême ne suffit pas.

**Exercice 0.0.5** (Lire une dispersion). Deux classes ont la même moyenne à un examen : 12/20. La classe A a un écart-type de 1,5 et la classe B un écart-type de 4.

- a. Quelle classe est la plus homogène ?  
b. Que signifie l'écart-type plus élevé de la classe B ?  
c. Peut-on dire que les étudiants de B ont de moins bonnes notes ?

💡 Solution de l'exercice Exercice 0.0.5

- a. La classe **A** est plus homogène.  
b. Les notes de B sont plus éloignées de leur moyenne : les niveaux sont davantage dispersés.  
c. Non. Les deux moyennes sont identiques ; B est seulement plus hétérogène.

**Exercice 0.0.6** (Choisir le bon graphique). Associez chaque besoin à un graphique : histogramme, courbe, barres, boîte à moustaches ou nuage de points.

- Comparer le chiffre d'affaires de quatre régions.
- Observer le nombre de commandes chaque mois.
- Repérer des valeurs extrêmes dans les salaires.
- Étudier le lien entre surface et prix d'un logement.

💡 Solution de l'exercice Exercice 0.0.6

- a. **Barres** ; b. **Courbe** ; c. **Boîte à moustaches** ; d. **Nuage de points**. Un histogramme serait adapté pour la répartition d'une seule variable numérique.

**Exercice 0.0.7** (Corrélation et causalité). Dans une ville, le nombre de glaces vendues et le nombre de baignades augmentent tous les deux en été.

- Quelle relation statistique peut-on observer ?
- Pourquoi ne peut-on pas conclure que les glaces provoquent les baignades ?
- Quelle variable cachée peut expliquer les deux évolutions ?

💡 Solution de l'exercice Exercice 0.0.7

- Une corrélation positive.
- Une corrélation décrit une association, pas une cause.
- La **température** ou la saison : le beau temps favorise à la fois l'achat de glaces et les baignades.

**Exercice 0.0.8** (Interpréter un tableau agrégé). Un tableau par région présente les résultats suivants :

| Région | Nombre de commandes | Montant moyen (MAD) |
|--------|---------------------|---------------------|
| Nord   | 100                 | 180                 |
| Centre | 20                  | 350                 |
| Sud    | 80                  | 200                 |

- Quelle région a le montant moyen le plus élevé ?
- Pourquoi faut-il également regarder le nombre de commandes ?
- Calculez le montant total estimé pour chaque région et identifiez la région au total le plus élevé.

💡 Solution de l'exercice Exercice 0.0.8

- Le **Centre** (350 MAD).
- Sa moyenne repose sur seulement 20 commandes ; elle est donc moins représentative d'un volume important que celle d'une région avec beaucoup de commandes.
- Nord :  $100 \times 180 = \mathbf{18\,000}$  MAD ; Centre :  $20 \times 350 = \mathbf{7\,000}$  MAD ; Sud :  $80 \times 200 = \mathbf{16\,000}$  MAD. Le total le plus élevé est celui du **Nord**.

# Introduction à l'entrepôt de données

## 💡 Objectifs du chapitre

À la fin de ce chapitre, l'étudiant sera capable de :

- **Expliquer** pourquoi une organisation sépare souvent les systèmes opérationnels des données destinées à l'analyse ;
- **Distinguer** une base transactionnelle, un entrepôt de données, un lac de données et un datamart ;
- **Lire** un modèle en étoile composé d'une table de faits et de tables de dimensions ;
- **Définir** le grain d'une table de faits et choisir des mesures adaptées ;
- **Décrire** les grandes étapes d'un flux ETL/ELT, de la source au tableau de bord.

Un tableau de bord fiable ne commence pas par un graphique. Il commence par des données organisées, documentées et mises à jour de façon régulière. L'**entrepôt de données** (*data warehouse*) fournit cette base pour l'analyse.

## 1. Pourquoi un entrepôt de données ?

### 1.1. Les systèmes opérationnels

Une application de vente, une caisse ou un site web utilise une base **opérationnelle** pour enregistrer les événements du quotidien : créer une commande, modifier une adresse, enregistrer un paiement. Ces systèmes doivent répondre vite à de petites opérations et éviter les incohérences.

Une base opérationnelle est souvent organisée pour limiter la répétition des informations. Une commande peut être répartie entre `clients`, `commandes` et `lignes_commande`, reliées par des identifiants.

Cette organisation est adaptée à l'écriture, mais une question analytique comme « Quel est le chiffre d'affaires mensuel par région et par catégorie depuis trois ans ? » peut nécessiter de nombreuses jointures et plusieurs sources. Exécuter ce type de requête directement sur la base de production peut ralentir l'application.

### 1.2. La base analytique

Un **entrepôt de données** est un espace centralisé, organisé pour analyser l'historique de l'organisation. Il rassemble des données provenant de plusieurs sources, conserve leur contexte et les transforme dans un format plus simple à interroger.

| Système                    | But principal                            | Exemple de question                                  |
|----------------------------|------------------------------------------|------------------------------------------------------|
| Base opérationnelle (OLTP) | Enregistrer les événements courants      | « Quel est le statut de la commande 1524 ? »         |
| Entrepôt analytique (OLAP) | Comparer, agréger et suivre l'historique | « Comment les ventes ont-elles évolué par région ? » |

Les deux systèmes sont complémentaires. L'entrepôt n'a pas pour objectif de remplacer l'application métier.

### 1.3. Entrepôt, lac et datamart

- Un **data warehouse** contient des données structurées, préparées et gouvernées pour l'analyse.
- Un **data lake** peut stocker des données brutes de formats variés (fichiers, textes, événements) avant leur usage ; il demande des règles claires pour rester compréhensible.
- Un **datamart** est une partie orientée vers un besoin ou un service, par exemple un datamart des ventes ou des ressources humaines.

⚠ Un entrepôt ne corrige pas une mauvaise question

Centraliser beaucoup de données ne suffit pas. Il faut définir le vocabulaire métier, les unités, la fréquence de mise à jour et les indicateurs attendus. Sinon, on obtient plusieurs chiffres différents pour un même « chiffre d'affaires ».

## 2. Le modèle en étoile

Le modèle en étoile est une organisation pédagogique et professionnelle très fréquente pour les données analytiques. Il place une **table de faits** au centre et des **tables de dimensions** autour.

### 2.1. La table de faits

Une table de faits contient les événements mesurables : ventes, livraisons, appels ou visites. Elle comprend généralement :

- des clés vers les dimensions (`client_id`, `produit_id`, `date_id`, `magasin_id`) ;
- des mesures numériques (`quantite`, `montant`, `remise`) ;
- une ligne par événement selon un niveau de détail défini.

Le **grain** est la phrase qui précise ce que représente une ligne. Par exemple : « une ligne représente un produit d'une commande, dans un magasin, à une date donnée ». Le grain doit être défini avant de choisir les mesures.

### 2.2. Les tables de dimensions

Une dimension décrit le contexte d'un fait :

- `dim_date` : jour, mois, trimestre, année ;
- `dim_produit` : produit, catégorie, marque ;
- `dim_client` : ville, région, segment ;
- `dim_magasin` : magasin, ville, zone.

Les dimensions contiennent les attributs utilisés pour filtrer, regrouper et expliquer les mesures. Elles sont souvent dénormalisées pour rendre l'exploration plus simple.

```

      dim_date
      |
dim_client ---- fact_ventes ---- dim_produit
      |
      dim_magasin
```

## 2.3. Exemple de modèle de ventes

```
fact_ventes
-----
date_id
produit_id
client_id
magasin_id
quantite
prix_unitaire
remise
montant_net

dim_produit
-----
produit_id
libelle
categorie
marque

dim_date
-----
date_id
date_complete
mois
trimestre
annee
```

Le montant net peut être calculé par :

$$\text{montant\_net} = \text{quantité} \times \text{prix unitaire} - \text{remise}.$$

Un modèle en étoile ne dicte pas un seul outil : il peut être utilisé dans une base SQL, un fichier analytique ou un modèle Power BI.

### **i** Le rôle de la dimension Date

Même si la source contient déjà une date, une dimension Date facilite les regroupements par mois, trimestre, semaine ou jour ouvré. Elle permet aussi de définir clairement les périodes comparées.

## 3. Les mesures et les indicateurs

Une **mesure additive** peut être additionnée sur toutes les dimensions, comme le nombre d'articles ou le montant des ventes. Une mesure **semi-additive**, comme un stock de fin de journée, peut être additionnée par produit mais pas dans le temps. Une mesure **non additive**, comme un taux ou une moyenne, doit être recalculée à partir de ses éléments plutôt que sommée.

Exemple : si une région a 10 commandes et une autre 2 commandes, la moyenne globale ne doit pas être calculée comme la moyenne des deux moyennes si les effectifs sont différents. Il faut utiliser :

$$\text{moyenne globale} = \frac{\text{total des montants}}{\text{nombre total de commandes}}.$$

Les noms des indicateurs doivent préciser leur définition. « Ventes » peut signifier chiffre d'affaires brut, chiffre d'affaires net, commandes payées ou unités vendues. Dans un dictionnaire métier, on documente la formule, l'unité, la période et les filtres.

## 4. Le flux ETL/ELT

Les données passent généralement par un flux en plusieurs étapes :

1. **Extract (extraire)** : lire les sources opérationnelles, fichiers ou API ;
2. **Transform (transformer)** : convertir les dates, harmoniser les unités, dédupliquer, contrôler les valeurs et calculer les champs dérivés ;
3. **Load (charger)** : déposer les données préparées dans les tables de l'entrepôt.

Dans une approche **ELT**, on charge d'abord les données dans une plateforme capable de les traiter, puis on réalise les transformations à l'intérieur de cette plateforme. Les deux approches poursuivent le même but : rendre les données fiables et exploitables.

Un chargement quotidien doit pouvoir répondre à quatre questions simples : quelles sources ont été lues ? combien de lignes ont été reçues ? combien ont été rejetées ? quand le chargement s'est-il terminé ?

### ! Qualité et traçabilité

Conservez les données sources ou un journal de chargement, le nombre de lignes avant et après transformation, les erreurs détectées et la date de mise à jour. Ces informations permettent de comprendre pourquoi un indicateur a changé.

## 5. Gouvernance et sécurité, sans complexité inutile

La **gouvernance** désigne les règles qui rendent les données compréhensibles, accessibles aux bonnes personnes et utilisées de manière responsable. Pour commencer, un projet peut mettre en place :

- un dictionnaire des tables et des indicateurs ;
- un responsable pour chaque donnée importante ;
- des règles de qualité (unicité d'un identifiant, prix positif, date obligatoire) ;
- des droits d'accès adaptés, notamment pour les données personnelles ;
- une fréquence de mise à jour annoncée.

Un tableau de bord ne devrait pas exposer inutilement des noms, numéros de téléphone ou adresses. On peut agréger les résultats, masquer les colonnes sensibles et limiter les accès selon le rôle de l'utilisateur.

### i Auto-évaluation

Avant de passer au chapitre suivant, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je sais expliquer la différence entre OLTP et OLAP.
- ☐ Je peux définir le grain d'une table de faits.
- ☐ Je peux reconnaître une dimension et une mesure dans un exemple.
- ☐ Je sais distinguer ETL et ELT.

☐ Je comprends pourquoi les indicateurs doivent être documentés.

## Exercices

### Consigne

Les exercices vérifient la compréhension et peuvent être résolus sans ordinateur. Les calculs sont volontairement courts.

**Exercice 0.0.1** (OLTP ou OLAP ?). Indiquez si la question relève plutôt d'un système opérationnel ou analytique :

- Modifier l'adresse d'un client.
- Comparer les ventes des quatre derniers trimestres par région.
- Vérifier si une commande est payée.
- Calculer la médiane des délais de livraison de l'année.

### Solution de l'exercice Exercice 0.0.1

a. **OLTP** ; b. **OLAP** ; c. **OLTP** ; d. **OLAP**.

**Exercice 0.0.2** (Identifier le grain). Une table **fact\_ventes** contient une ligne par produit présent dans une commande. Formulez le grain avec une phrase et expliquez pourquoi une commande de trois produits peut produire trois lignes.

### Solution de l'exercice Exercice 0.0.2

Le grain est : **une ligne représente un produit d'une commande**. Une commande contenant trois produits possède donc trois lignes de détail, même si elle n'a qu'un seul numéro de commande.

**Exercice 0.0.3** (Faits ou dimensions). Classez les éléments suivants : **montant\_net**, **categorie**, **annee**, **quantite**, **ville\_client**, **prix\_unitaire**.

### Solution de l'exercice Exercice 0.0.3

Faits ou mesures : **montant\_net**, **quantite**, **prix\_unitaire**. Dimensions ou attributs de dimensions : **categorie**, **annee**, **ville\_client**.

**Exercice 0.0.4** (Calculer une mesure). Une ligne indique 3 articles à 120 MAD chacun et une remise de 40 MAD. Calculez le montant net. Une deuxième ligne indique 2 articles à 80 MAD sans remise. Quel est le montant total des deux lignes ?

### Solution de l'exercice Exercice 0.0.4

Première ligne :  $3 \times 120 - 40 = \mathbf{320}$  MAD. Deuxième ligne :  $2 \times 80 = \mathbf{160}$  MAD. Total :  $320 + 160 = \mathbf{480}$  MAD.

**Exercice 0.0.5** (Mesure additive ou non ?). Indiquez si l'on peut additionner directement la mesure sur les périodes suivantes :

- Le montant de ventes.
- Le stock disponible à la fin de chaque jour.
- Un taux de conversion en pourcentage.

 Solution de l'exercice Exercice 0.0.5

- Le montant de ventes est **additif**.
- Le stock de fin de journée est **semi-additif** : on peut comparer ou prendre le dernier stock, mais le sommer sur les jours n'a généralement pas de sens.
- Un taux est **non additif** : il faut recalculer le taux à partir des numérateurs et dénominateurs.

**Exercice 0.0.6** (Comprendre ETL). Remettez dans l'ordre : charger les données préparées, extraire un fichier CSV, convertir les dates et contrôler les prix négatifs.

 Solution de l'exercice Exercice 0.0.6

- Extraire le fichier CSV.
- Convertir les dates et contrôler les prix négatifs.
- Charger les données préparées.

**Exercice 0.0.7** (Moyenne globale). La région A compte 10 commandes de 100 MAD en moyenne. La région B compte 2 commandes de 300 MAD en moyenne.

- Quel est le total estimé de chaque région ?
- Calculez la moyenne globale.
- Pourquoi la moyenne des deux moyennes, 200 MAD, est-elle incorrecte ?

 Solution de l'exercice Exercice 0.0.7

- A :  $10 \times 100 = 1\,000$  MAD ; B :  $2 \times 300 = 600$  MAD.
- Moyenne globale :  $(1000 + 600)/(10 + 2) = 1600/12 = 133,33$  MAD environ.
- Les régions n'ont pas le même nombre de commandes ; la moyenne de 200 MAD donne le même poids aux deux groupes.

**Exercice 0.0.8** (Qualité et sécurité). Proposez une règle de qualité et une mesure de protection pour chacune des situations :

- La colonne **prix** contient parfois des valeurs négatives.
- Un tableau de bord doit être partagé avec des responsables régionaux.

 Solution de l'exercice Exercice 0.0.8

- Règle : **prix**  $\geq 0$ , avec rejet ou examen des exceptions.
- Protection : filtrer les données selon la région de l'utilisateur et ne partager que les colonnes nécessaires ; les noms ou coordonnées personnelles peuvent être masqués.

# Business Intelligence avec Power BI et Taipy

## 💡 Objectifs du chapitre

À la fin de ce chapitre, l'étudiant sera capable de :

- **Définir** la Business Intelligence et distinguer un indicateur, un rapport et un tableau de bord ;
- **Construire** mentalement le parcours d'une donnée depuis la source jusqu'à une décision ;
- **Importer et préparer** des données dans Power BI avec Power Query ;
- **Comprendre** un modèle en étoile et créer des mesures simples en DAX ;
- **Choisir** entre Power BI et une application Python avec Taipy selon le besoin ;
- **Expliquer** les principes d'un tableau de bord lisible : objectif, public, filtres, contexte et action.

La **Business Intelligence (BI)** transforme des données préparées en informations régulièrement consultées pour piloter une activité. Elle ne consiste pas à accumuler des graphiques : un bon tableau de bord aide une personne précise à répondre à des questions précises et à décider.

## 1. Comprendre la BI

### 1.1. Du besoin à l'indicateur


Un **indicateur** est une mesure définie par une formule, une période et une population. Un **KPI** (*Key Performance Indicator*) est un indicateur considéré comme essentiel pour suivre un objectif.

Exemple pour un site de livraison :

| Élément         | Exemple                                   |
|-----------------|-------------------------------------------|
| Objectif        | Livrer les commandes à temps              |
| KPI             | Taux de livraison à temps                 |
| Formule         | livraisons à temps / livraisons terminées |
| Période         | semaine ou mois                           |
| Cible           | au moins 95 %                             |
| Action possible | examiner les villes sous la cible         |

Un rapport peut contenir plusieurs pages et analyses détaillées. Un tableau de bord est généralement plus synthétique : il met en évidence les quelques indicateurs et alertes nécessaires au suivi.

### 1.2. Le parcours d'une solution BI



Le modèle **sémantique** donne un sens commun aux tables, aux relations et aux mesures. Deux personnes doivent obtenir le même chiffre lorsqu'elles utilisent le même KPI.

### 1.3. Règles d'un tableau de bord débutant

Un tableau de bord lisible :

1. commence par le public et la décision attendue ;
2. affiche une période et une unité ;
3. présente quelques KPI importants avant les détails ;
4. utilise une couleur pour signaler une information, pas pour décorer chaque objet ;
5. permet d'explorer sans cacher la définition des indicateurs ;
6. indique la date de dernière actualisation.

## 2. Power BI : une démarche structurée

Power BI est une plateforme de Business Intelligence qui permet de connecter des sources, de les transformer, de créer un modèle de données, de calculer des mesures et de construire des rapports interactifs. Le parcours présenté ici commence dans Power BI Desktop ; le partage dépend ensuite de l'environnement et des droits de l'organisation.

### 2.1. Étape 1 — Importer les sources

On peut importer un fichier CSV, un classeur Excel, une base SQL ou d'autres sources disponibles dans l'environnement. À l'import, il faut vérifier :

- les noms de colonnes et leurs types ;
- le séparateur et l'encodage d'un CSV ;
- le type date, nombre ou texte ;
- le nombre de lignes et la période couverte ;
- la présence de doublons et de valeurs manquantes.

Importer n'est pas encore analyser : il faut comprendre ce qui a été chargé.

### 2.2. Étape 2 — Transformer avec Power Query

**Power Query** sert à préparer les données avant leur utilisation dans le modèle. On peut supprimer des colonnes inutiles, renommer un champ, convertir un type, filtrer des lignes, remplacer une valeur, fusionner des tables ou ajouter une colonne calculée.

Une transformation doit rester explicable et reproductible. Power Query conserve les étapes appliquées ; il vaut mieux créer plusieurs étapes nommées et simples qu'une modification manuelle impossible à refaire.


Exemples de contrôles :

- **Montant** est numérique et positif ;

- DateCommande est bien de type date ;
- ProduitID et DateID sont présents ;
- la catégorie vide est traitée explicitement ;
- le nombre de lignes final est comparé au nombre attendu.

### 2.3. Étape 3 — Construire le modèle

Pour un modèle de ventes, on privilégie un schéma en étoile :



La table de faits contient les lignes de vente et les dimensions permettent de filtrer par date, produit, client ou magasin. Les relations doivent être vérifiées : une dimension possède généralement une ligne par identifiant, et plusieurs lignes de faits peuvent lui être liées.

#### Le piège des relations ambiguës

Si une dimension contient plusieurs lignes pour le même identifiant, ou si deux tables sont reliées de manière inattendue, les totaux peuvent être multipliés. Vérifiez toujours le grain, les clés et un total connu avant de publier un rapport.

### 2.4. Étape 4 — Créer des mesures en DAX

DAX est le langage de formules utilisé dans les modèles Power BI. Une **mesure** est recalculée selon le contexte de filtre du visuel, de la page ou de l'utilisateur.

```

ChiffreAffaires = SUM(fact_Ventes[MontantNet])

NombreCommandes = DISTINCTCOUNT(fact_Ventes[CommandeID])

PanierMoyen = DIVIDE([ChiffreAffaires], [NombreCommandes])

```

DIVIDE évite une erreur lorsque le dénominateur est nul. Pour débiter, il faut distinguer une mesure d'une colonne calculée : la mesure s'adapte aux filtres, tandis qu'une colonne calculée est créée ligne par ligne dans la table.

Une mesure peut être comparée à une période précédente, mais la logique de dates doit être préparée soigneusement. Dans un premier tableau de bord, trois ou quatre mesures bien définies valent mieux que de nombreuses formules difficiles à expliquer.

### 2.5. Étape 5 — Construire les visuels

Pour une page de suivi des ventes, une composition simple peut être :

- une ligne de cartes KPI : chiffre d'affaires, commandes, panier moyen, taux de livraison à temps ;
- une courbe du chiffre d'affaires par mois ;
- un graphique en barres par région ou catégorie ;

- un tableau détaillé filtrable ;
- des segments (*slicers*) pour l'année, la région et la catégorie.

Chaque visuel doit répondre à une question. Un graphique avec trop de séries ou trop de couleurs devient difficile à lire.

## 2.6. Étape 6 — Vérifier et partager

Avant tout partage, vérifiez les totaux sur un petit exemple connu, la date d'actualisation, les filtres, les titres et les droits d'accès. Un rapport partagé avec des données personnelles doit respecter les règles de l'organisation et le principe du moindre accès.

## 3. Taipy : créer une application BI en Python

Taipy permet de construire des applications Python interactives avec des contrôles, des graphiques, des tableaux et des filtres. Il est particulièrement intéressant quand l'équipe veut intégrer l'analyse dans une application métier ou conserver une logique Python personnalisée.

### 3.1. Quand choisir Taipy ?

Taipy peut être pertinent lorsque :

- les traitements sont déjà écrits en Python ;
- l'application doit combiner un tableau de bord avec une logique métier ;
- l'on veut contrôler l'interface et le déploiement comme un projet logiciel ;
- l'utilisateur doit modifier un paramètre et observer immédiatement un résultat.

Power BI peut être plus adapté lorsqu'une organisation veut une solution de BI prête à l'emploi, un catalogue de rapports, des connexions gérées et des usages majoritairement orientés vers l'exploration métier.

Ce ne sont pas des outils absolument opposés. Une équipe peut préparer les données avec Python, les exposer dans Power BI, ou intégrer un indicateur Power BI dans un parcours applicatif selon son architecture.

### 3.2. Un exemple Taipy minimal

Le code suivant illustre le principe avec des données déjà disponibles. Il ne remplace pas la préparation et la validation des données.

```
import pandas as pd
from taipy.gui import Gui

df = pd.DataFrame({
    "Mois": ["Janvier", "Février", "Mars"],
    "Ventes": [12000, 14500, 13200],
})

mois = "Tous"
texte = "### Suivi des ventes"

page = ""
# Suivi des ventes
```

```
Sélection : <|{mois}|selector|lov=Tous;Janvier;Février;Mars|>

<|{df}|table|>
"""

Gui(page=page).run()
```

Dans cet exemple, `df` contient les données affichées, `page` décrit l'interface et le sélecteur permet de choisir une valeur. Dans un vrai projet, on ajoute une fonction qui filtre les données, des indicateurs calculés et des graphiques adaptés. Les noms exacts de certains contrôles peuvent évoluer selon la version de Taipy : il faut vérifier la documentation de la version utilisée.

### 3.3. Organiser une petite application

Même une application pédagogique gagne à séparer :

```
projet/
  data/                # données sources ou exemple
  preparation.py        # lecture et nettoyage
  indicateurs.py        # calculs métier
  app.py                # interface Taipy
  README.md             # installation et utilisation
```

Cette séparation permet de tester les indicateurs indépendamment de l'interface. L'application ne doit pas recalculer silencieusement un indicateur avec une définition différente de celle du rapport.

## 4. Comparaison synthétique

| Critère           | Power BI                                | Taipy                                        |
|-------------------|-----------------------------------------|----------------------------------------------|
| Profil            | Plateforme BI avec interface graphique  | Bibliothèque/applications Python             |
| Préparation       | Power Query et connexions               | Python, pandas ou autres outils              |
| Mesures           | DAX et modèle sémantique                | Fonctions et code Python                     |
| Usage principal   | Rapports, exploration et partage BI     | Application interactive intégrée à un projet |
| Point d'attention | Relations, contexte des mesures, droits | Organisation du code, déploiement, versions  |

Le choix doit partir du besoin, pas de la préférence pour un outil. Dans les deux cas, les mêmes bases restent indispensables : question métier, qualité des données, modèle clair, indicateurs documentés et visualisation lisible.

#### i Auto-évaluation

Avant le cas pratique, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je peux distinguer un KPI, une mesure et un visuel.
- ☐ Je sais expliquer le rôle de Power Query.
- ☐ Je peux décrire la place de la table de faits dans un modèle Power BI.

- ☐ Je sais pourquoi une mesure DAX n'est pas toujours une colonne calculée.
- ☐ Je peux citer une situation où Taipy est pertinent.
- ☐ Je sais vérifier un tableau de bord avant de le partager.

## Exercices

### Consigne

Ces exercices sont conceptuels ou demandent seulement un calcul court. Aucun logiciel n'est nécessaire.

**Exercice 0.0.1** (Indicateur ou action?). Pour l'objectif « réduire les retards de livraison », proposez un KPI, sa formule et une action possible si sa valeur diminue.

### Solution de l'exercice Exercice 0.0.1

Exemple : KPI = **taux de livraison à temps** ; formule = livraisons à temps / livraisons terminées  $\times 100$  ; action = analyser les villes ou transporteurs dont le taux est le plus faible.

**Exercice 0.0.2** (Lire un parcours BI). Associez chaque étape à son rôle : préparer, modéliser, visualiser, décider.

- a. Relier les ventes à la dimension Date.
- b. Convertir une colonne texte en date.
- c. Afficher les ventes par mois.
- d. Renforcer un transporteur après avoir constaté des retards.

### Solution de l'exercice Exercice 0.0.2

a. **Modéliser** ; b. **Préparer** ; c. **Visualiser** ; d. **Décider**.

**Exercice 0.0.3** (Calculer un KPI). Sur 250 livraisons terminées, 225 ont été livrées à temps. Calculez le taux de livraison à temps et indiquez s'il atteint une cible de 95 %.

### Solution de l'exercice Exercice 0.0.3

$225/250 \times 100 = 90\%$ . Le taux n'atteint pas la cible de 95 %.

**Exercice 0.0.4** (Power Query ou DAX?). Indiquez l'outil le plus adapté :

- a. Corriger le type d'une colonne **Date**.
- b. Calculer le chiffre d'affaires selon les filtres du rapport.
- c. Supprimer une colonne inutilisée avant le modèle.

### Solution de l'exercice Exercice 0.0.4

a. **Power Query** ; b. **mesure DAX** ; c. **Power Query**.

**Exercice 0.0.5** (Vérifier une relation). Une dimension **Produit** contient deux lignes pour le même **ProduitID**. Quel risque cela crée-t-il lorsqu'on relie cette dimension à une table de ventes ? Quelle vérification simple proposeriez-vous ?

💡 Solution de l'exercice Exercice 0.0.5

Les ventes peuvent être comptées plusieurs fois lors d'un regroupement ou d'un filtre. Il faut vérifier l'unicité de **ProduitID** dans la dimension et retrouver la cause du doublon avant de publier.

**Exercice 0.0.6** (Choisir un outil). Une équipe possède déjà plusieurs fonctions Python et veut intégrer un indicateur interactif dans une application interne. Une autre équipe veut surtout créer rapidement des rapports métiers partagés. Quel outil recommander à chacune, et pourquoi ?

💡 Solution de l'exercice Exercice 0.0.6

La première équipe peut choisir **Taipy**, pour réutiliser sa logique Python dans une application. La seconde peut choisir **Power BI**, orienté vers les modèles, rapports et usages BI partagés. Le contexte de sécurité et de déploiement doit aussi être vérifié.

**Exercice 0.0.7** (Lire une mesure). Le chiffre d'affaires est de 48 000 MAD pour 300 commandes.

- a. Calculez le panier moyen.
- b. Pourquoi faut-il utiliser le nombre de commandes et non le nombre de lignes de produits si le KPI est défini par commande ?

💡 Solution de l'exercice Exercice 0.0.7

- a.  $48\,000/300 = \mathbf{160}$  MAD par commande.
- b. Une commande peut contenir plusieurs lignes de produits ; compter les lignes gonflerait le dénominateur et changerait la définition du KPI.

**Exercice 0.0.8** (Critiquer une page). Une page affiche 25 graphiques sans unité, sans date de mise à jour et avec une couleur différente pour chaque barre. Citez trois améliorations prioritaires et justifiez-les.

💡 Solution de l'exercice Exercice 0.0.8

Exemples : réduire le nombre de visuels pour mettre en avant les KPI ; ajouter titres, unités et période ; afficher la date d'actualisation ; réserver les couleurs aux catégories ou alertes utiles ; ajouter des filtres compréhensibles. Ces changements facilitent la lecture et évitent des interprétations différentes.

# Cas pratique complet : analyser les ventes d'une petite chaîne de magasins

## 💡 Objectifs du chapitre

À la fin de ce cas pratique, l'étudiant sera capable de :

- **Cadrer** une question d'analyse à partir d'un besoin métier ;
- **Repérer** les problèmes de qualité dans un petit jeu de données ;
- **Calculer et interpréter** des indicateurs simples : chiffre d'affaires, quantité, panier moyen, médiane et taux ;
- **Choisir** un modèle en étoile adapté à une analyse de ventes ;
- **Proposer** une page Power BI et une vue Taipy cohérentes avec les questions ;
- **Rédiger** une conclusion prudente, fondée sur les données et accompagnée de limites.

Ce chapitre suit un projet de bout en bout. L'entreprise fictive **Atlas Marchés** possède trois magasins à Casablanca, Rabat et Tanger. La direction souhaite comprendre les ventes du premier trimestre 2026 et décider où concentrer ses efforts commerciaux. Les données sont volontairement petites afin que les calculs puissent être vérifiés à la main.

## 1. Le besoin métier

La direction pose quatre questions :

1. Quel est le chiffre d'affaires net par mois et par magasin ?
2. Quels produits ou catégories contribuent le plus aux ventes ?
3. Le panier moyen est-il différent selon les magasins ?
4. Quelles informations faudrait-il surveiller dans un tableau de bord mensuel ?

La question n'est pas « faire un graphique ». Le livrable attendu est une analyse descriptive, quelques explications prudentes et une proposition de suivi.

### 1.1. Périmètre et définitions

Le périmètre est limité aux ventes **payées** enregistrées entre le 1er janvier et le 31 mars 2026. Une ligne du fichier correspond à une ligne de produit dans une commande. Le montant net est défini ainsi :

$$\text{montant net} = \text{quantité} \times \text{prix unitaire} - \text{remise}.$$

Le **panier moyen** est :

$$\text{panier moyen} = \frac{\text{chiffre d'affaires net}}{\text{nombre de commandes distinctes}}.$$

Ces définitions sont annoncées avant les calculs ; elles évitent de changer de formule au milieu de l'analyse.

## 2. Le jeu de données

Voici un extrait pédagogique. Dans un vrai projet, le fichier complet pourrait contenir beaucoup plus de lignes.

| Ligne | Commande | Date       | Magasin    | Catégorie | Produit | Qté | Prix unitaire | Remise | Statut  |
|-------|----------|------------|------------|-----------|---------|-----|---------------|--------|---------|
| 1     | C001     | 05/01/2026 | Casablanca | Épicerie  | Huile   | 2   | 75            | 0      | Payée   |
| 2     | C001     | 05/01/2026 | Casablanca | Épicerie  | Riz     | 3   | 20            | 0      | Payée   |
| 3     | C002     | 08/01/2026 | Rabat      | Boissons  | Jus     | 4   | 18            | 5      | Payée   |
| 4     | C003     | 15/01/2026 | Tanger     | Hygiène   | Savon   | 5   | 12            | 0      | Payée   |
| 5     | C004     | 03/02/2026 | Casablanca | Épicerie  | Huile   | 1   | 75            | 0      | Payée   |
| 6     | C005     | 10/02/2026 | Rabat      | Épicerie  | Riz     | 5   | 20            | 10     | Payée   |
| 7     | C006     | 18/02/2026 | Tanger     | Boissons  | Jus     | 2   | 18            | 0      | Annulée |
| 8     | C007     | 22/02/2026 | Casablanca | Hygiène   | Savon   | 6   | 12            | 0      | Payée   |
| 9     | C008     | 06/03/2026 | Rabat      | Boissons  | Jus     | 6   | 18            | 0      | Payée   |
| 10    | C009     | 12/03/2026 | Tanger     | Épicerie  | Riz     | 2   | 20            | 0      | Payée   |
| 11    | C010     | 20/03/2026 | Casablanca | Boissons  | Jus     | 3   | 18            | 5      | Payée   |
| 12    | C010     | 20/03/2026 | Casablanca | Hygiène   | Savon   | 2   | 12            | 0      | Payée   |

### 2.1. Première lecture

Le grain est **une ligne de produit dans une commande**. La commande C001 apparaît deux fois car elle contient deux produits. Pour compter les commandes, il faut compter les identifiants distincts, et non les lignes.

La ligne C006 est annulée. Si le chiffre d'affaires concerne les ventes payées, elle doit être exclue, mais cette décision doit être documentée. Elle ne doit pas être supprimée du fichier original : on conserve le statut pour pouvoir analyser les annulations.

## 3. Préparer les données

### 3.1. Dictionnaire minimal

| Colonne       | Type attendu | Règle                               |
|---------------|--------------|-------------------------------------|
| Commande      | Texte        | Identifiant non vide                |
| Date          | Date         | Date comprise dans la période       |
| Magasin       | Catégorie    | Casablanca, Rabat ou Tanger         |
| Qté           | Entier       | Strictement positive pour une vente |
| Prix unitaire | Décimal      | Positif, en MAD                     |
| Remise        | Décimal      | Supérieure ou égale à 0, en MAD     |
| Statut        | Catégorie    | Payée ou Annulée                    |

Il faut également vérifier que la remise ne dépasse pas le montant brut de la ligne, que les dates ne sont pas inversées et que les identifiants ne comportent pas d'espaces cachés.

### 3.2. Transformation

Pour chaque ligne, on calcule :

```
montant_brut = quantité × prix_unitaire
montant_net = montant_brut - remise
mois = mois(date)
```

Puis on filtre `Statut = Payée` pour les indicateurs de chiffre d'affaires. On conserve une copie de l'ensemble initial et on compte les lignes exclues.

Pour l'extrait, 11 lignes sur 12 sont payées. La ligne annulée représente 1 ligne sur 12, soit environ 8,3 % des lignes ; ce pourcentage ne doit pas être interprété comme un taux de commandes annulées, car une commande peut comporter plusieurs lignes.

## 4. Calculer les indicateurs

### 4.1. Montants ligne par ligne

Sur les lignes payées :

| Commande | Produit | Calcul             | Montant net |
|----------|---------|--------------------|-------------|
| C001     | Huile   | $2 \times 75 - 0$  | 150         |
| C001     | Riz     | $3 \times 20 - 0$  | 60          |
| C002     | Jus     | $4 \times 18 - 5$  | 67          |
| C003     | Savon   | $5 \times 12 - 0$  | 60          |
| C004     | Huile   | $1 \times 75 - 0$  | 75          |
| C005     | Riz     | $5 \times 20 - 10$ | 90          |
| C007     | Savon   | $6 \times 12 - 0$  | 72          |
| C008     | Jus     | $6 \times 18 - 0$  | 108         |
| C009     | Riz     | $2 \times 20 - 0$  | 40          |
| C010     | Jus     | $3 \times 18 - 5$  | 49          |
| C010     | Savon   | $2 \times 12 - 0$  | 24          |

Le chiffre d'affaires net de l'extrait est donc :

$$150 + 60 + 67 + 60 + 75 + 90 + 72 + 108 + 40 + 49 + 24 = \mathbf{795 \text{ MAD.}}$$

| Mois | Chiffre d'affaires net | Commandes distinctes | Panier moyen |
|------|------------------------|----------------------|--------------|
|------|------------------------|----------------------|--------------|

## 4.2. Par mois

| Mois         | Chiffre d'affaires net | Commandes distinctes | Panier moyen |
|--------------|------------------------|----------------------|--------------|
| Janvier      | 337                    | 3                    | 112,33       |
| Février      | 237                    | 3                    | 79,00        |
| Mars         | 221                    | 3                    | 73,67        |
| <b>Total</b> | <b>795</b>             | <b>9</b>             | <b>88,33</b> |

Le panier moyen total est  $795/9 = 88,33$  MAD. Il ne faut pas faire la moyenne simple des trois paniers mensuels sans vérifier les effectifs ; ici ils sont égaux, mais ce n'est pas toujours le cas.

## 4.3. Par magasin et par catégorie

En regroupant les lignes payées :

| Magasin    | Chiffre d'affaires net | Commandes distinctes | Panier moyen |
|------------|------------------------|----------------------|--------------|
| Casablanca | 435                    | 4                    | 108,75       |
| Rabat      | 157                    | 3                    | 52,33        |
| Tanger     | 100                    | 2                    | 50,00        |

| Catégorie | Chiffre d'affaires net |
|-----------|------------------------|
| Épicerie  | 415                    |
| Boissons  | 224                    |
| Hygiène   | 156                    |

Casablanca contribue le plus au chiffre d'affaires et possède le panier moyen le plus élevé dans cet extrait. Cela ne suffit pas à conclure que le magasin est le plus performant : il faudrait connaître le nombre de visiteurs, les coûts, la taille des magasins et une période plus longue.

## 4.4. Moyenne et médiane des montants de lignes

Les montants des lignes payées sont :

60, 60, 67, 72, 75, 90, 108, 24, 40, 49, 150

Triés :

24, 40, 49, 60, 60, 67, 72, 75, 90, 108, 150.

La médiane est la sixième valeur, soit **67 MAD**. La moyenne est  $795/11 \approx 72,27$  MAD. La moyenne un peu supérieure à la médiane suggère que quelques lignes élevées, notamment 150 MAD, tirent la moyenne vers le haut.

## 5. Construire le modèle analytique

À partir de ce fichier, un modèle en étoile simple pourrait être :

```
dim_date -----\
dim_produit ----- fact_ventes
dim_magasin -----/
```

fact\_ventes contient Commande, DateID, ProduitID, MagasinID, Quantite, PrixUnitaire, Remise, MontantNet et Statut. Les dimensions décrivent les dates, produits et magasins.

Les mesures attendues sont :

```
ChiffreAffaires = somme de MontantNet pour les lignes payées
Commandes = nombre d'identifiants Commande distincts pour les lignes payées
PanierMoyen = ChiffreAffaires / Commandes
Quantités = somme de Quantite pour les lignes payées
```

Le tableau de bord ne doit pas calculer le panier moyen comme la moyenne des montants de lignes : une commande peut contenir plusieurs lignes. Le grain explique cette différence.

## 6. Concevoir la page Power BI

Une page « Vue générale » peut contenir :

1. quatre cartes : chiffre d'affaires net, commandes, panier moyen et quantités vendues ;
2. une courbe du chiffre d'affaires par mois ;
3. des barres du chiffre d'affaires par magasin ;
4. des barres du chiffre d'affaires par catégorie ;
5. des segments pour le mois, le magasin et la catégorie ;
6. une note indiquant « données payées, période janvier-mars 2026, dernière actualisation ».

Une deuxième page « Diagnostic » peut détailler les produits, les annulations et les différences entre magasins. La première page répond à « où en sommes-nous ? », la seconde aide à explorer « où regarder ensuite ? ».

Avant le partage, on compare les cartes aux totaux calculés manuellement : 795 MAD, 9 commandes distinctes et 88,33 MAD de panier moyen.

## 7. Construire une vue Taipy

La même analyse peut être intégrée à une application Python. La logique doit être séparée de l'affichage :

```
def indicateurs(df):
    payees = df[df["Statut"] == "Payée"]
    chiffre_affaires = payees["MontantNet"].sum()
    commandes = payees["Commande"].nunique()
    panier_moyen = chiffre_affaires / commandes if commandes else 0
    return {
        "chiffre_affaires": chiffre_affaires,
```

```
"commandes": commandes,
"panier_moyen": panier_moyen,
}
```

Une interface Taipy peut ensuite proposer un filtre **Magasin**, afficher les trois indicateurs et mettre à jour une table mensuelle. Le résultat doit rester cohérent avec le dictionnaire métier et les calculs Power BI.

## 8. Interpréter et communiquer

Une conclusion raisonnable pour l'extrait serait :

Sur les ventes payées de l'extrait, le chiffre d'affaires net atteint 795 MAD pour 9 commandes, avec un panier moyen de 88,33 MAD. Casablanca représente 435 MAD et le panier moyen y est supérieur à celui de Rabat et Tanger. Les lignes de vente ont une médiane de 67 MAD et une moyenne de 72,27 MAD, ce qui signale une légère influence de quelques montants élevés. Ces résultats sont exploratoires : l'échantillon est très petit, ne couvre que trois mois et ne permet pas d'expliquer les causes ni de mesurer la rentabilité.

La conclusion sépare les **faits calculés**, les **interprétations prudentes** et les **limites**. Elle ne transforme pas une différence observée en causalité.

### i Auto-évaluation

Avant de considérer le cas comme terminé, assurez-vous de pouvoir répondre « oui » aux questions suivantes :

- ☐ Je peux formuler le grain du fichier.
- ☐ Je sais pourquoi la ligne annulée est filtrée pour le chiffre d'affaires.
- ☐ Je peux recalculer le total de 795 MAD.
- ☐ Je distingue lignes de produits et commandes distinctes.
- ☐ Je peux expliquer la différence entre moyenne et médiane dans ce cas.
- ☐ Je peux proposer une page de tableau de bord sans surcharger l'utilisateur.

## Exercices

### i Consigne

Répondez sans ordinateur. Les données de l'énoncé suffisent ; les calculs sont courts et peuvent être réalisés avec une calculatrice.

**Exercice 0.0.1** (Définir le grain). Quelle phrase décrit le grain du fichier ? Pourquoi la commande C001 occupe-t-elle deux lignes ?

### 💡 Solution de l'exercice Exercice 0.0.1

Une ligne représente **un produit dans une commande**. C001 contient de l'huile et du riz : elle possède donc deux lignes de produits.

**Exercice 0.0.2** (Exclure une annulation). Pourquoi la ligne C006 n'est-elle pas incluse dans le chiffre d'affaires payé ? Peut-on la supprimer du fichier original ?

💡 Solution de l'exercice Exercice 0.0.2

Elle est marquée **Annulée**, donc elle ne représente pas une vente payée selon la définition du périmètre. Il faut la conserver dans la source afin de pouvoir suivre les annulations et documenter le filtre.

**Exercice 0.0.3** (Calculer une ligne). Calculez le montant net de 4 jus à 18 MAD avec une remise de 5 MAD, puis celui de 5 savons à 12 MAD sans remise.

💡 Solution de l'exercice Exercice 0.0.3

Jus :  $4 \times 18 - 5 = \mathbf{67}$  MAD. Savons :  $5 \times 12 = \mathbf{60}$  MAD.

**Exercice 0.0.4** (Vérifier le total). Le chiffre d'affaires net est de 795 MAD et le magasin de Casablanca réalise 435 MAD.

- Quelle part du chiffre d'affaires total représente Casablanca ?
- Quel montant reste pour Rabat et Tanger ensemble ?

💡 Solution de l'exercice Exercice 0.0.4

- $435/795 \times 100 \approx 54,7\%$ .
- $795 - 435 = \mathbf{360}$  MAD.

**Exercice 0.0.5** (Commandes et lignes). Il y a 11 lignes payées mais seulement 9 commandes distinctes.

- Pourquoi ces deux nombres sont-ils différents ?
- Quel nombre utiliser pour calculer le panier moyen ?

💡 Solution de l'exercice Exercice 0.0.5

- Certaines commandes contiennent plusieurs produits et donc plusieurs lignes ; C001 et C010 en sont des exemples.
- Il faut utiliser **9 commandes distinctes**, car le panier moyen est défini par commande.

**Exercice 0.0.6** (Comparer moyenne et médiane). La moyenne des montants de lignes est 72,27 MAD et la médiane est 67 MAD. Que suggère cette différence ? Quelle valeur de la liste contribue particulièrement à tirer la moyenne vers le haut ?

💡 Solution de l'exercice Exercice 0.0.6

La moyenne supérieure à la médiane suggère une légère asymétrie à droite : quelques montants élevés influencent la moyenne. La ligne à 150 MAD y contribue particulièrement.

**Exercice 0.0.7** (Choisir les indicateurs du tableau de bord). Parmi les éléments suivants, lesquels doivent apparaître en priorité sur la page générale : chiffre d'affaires net, identifiant de chaque client, commandes distinctes, panier moyen, une liste de 25 couleurs, date d'actualisation ? Justifiez les choix.

 Solution de l'exercice Exercice 0.0.7

Les priorités sont le **chiffre d'affaires net**, les **commandes distinctes**, le **panier moyen** et la **date d'actualisation**. Un identifiant individuel n'est pas nécessaire pour la vue générale et peut poser un problème de confidentialité ; 25 couleurs nuisent à la lecture.

**Exercice 0.0.8** (Limites et décisions). La direction demande : « Casablanca est-elle le meilleur magasin ? »

- a. Donnez une conclusion que les données permettent de soutenir.
- b. Citez deux informations manquantes avant de conclure sur la performance globale.

 Solution de l'exercice Exercice 0.0.8

- a. On peut dire que Casablanca a le chiffre d'affaires net et le panier moyen les plus élevés dans **cet extrait de ventes payées**.
- b. Il manque par exemple les coûts et la marge, le nombre de visiteurs, la taille des magasins, le stock disponible, une période plus longue et les objectifs de chaque magasin. Le chiffre d'affaires seul ne suffit pas à définir la performance globale.

## References

Knafllic, Cole. 2015. *Storytelling with Data*. Wiley.

McKinney, Wes. 2022. *Python for Data Analysis*. O'Reilly Media.